ejerciciospracticos-exploracion-vd

November 23, 2023

#Herramientas para la visualización de datos masivos

Objetivo: El objetivo de este cuaderno es cargar y realizar la exploración inicial de los datos utilizando el lenguaje de programación Python.

Exploración de Datos

Indice

Cargar los Datos

Visualizar los Datos

Tipos de datos

Visualizar las estadísticas

Identificar datos faltantes

Explorar relaciones entre los datos

Graficar las estadísticas

Exportar los datos

##Cargar los datos

Existen varios formatos para un conjunto de datos, .csv, .json, .xlsx, etc. Los datos pueden ser almacenados en distintos lugares, ya sea localmente o en línea. En estas sección aprenderá a cargar un conjunto de datos en su cuaderno de python. En nuestro caso el conjunto de datos Automobile es de una fuente en línea en formato CSV (valores separados por coma). Usemos este conjunto como ejemplo para practicar la lectura de datos.

fuente de datos: https://archive.ics.uci.edu/ml/machine-learning-databases/autos/imports-85.data

tipo de datos: csv

Vamos a utilizar la librería Pandas de Python para realizar la lectura de archivos. Le ponemos un alias pd para que sea más fácil utilizarla:

[ ]:
```
# Importar libreria requerida
import pandas as pd
import numpy as np
import os
```

Después del comando para importar, ahora tenemos acceso a una gran cantidad de clases y funciones predefinidas. Una forma en que pandas le permite trabajar con datos es con dataframes. Repasemos el proceso para pasar de un archivo de valores separados por comas (.csv) a un dataframe. Esta variable csv_path almacena la ruta de .csv, que se utiliza como argumento para la función read_csv. El resultado se almacena en el objeto df, esta es una forma corta común que se usa para una variable que se refiere a un dataframe de Pandas.

[ ]:
```
# ruta de archivos
files = os.listdir("c:\\archivos\proyecto")
os.chdir(r'C:\archivos\proyecto')

csv_path = 'ind_urgencias_final_2023_filtrado.txt'

# Read data from CSV file
df = pd.read_csv(csv_path,sep=";",header= None)
```

```
C:\Users\Victor.Gomez\AppData\Local\Temp\ipykernel_14576\2968785239.py:8:
DtypeWarning: Columns (10,12,17,18,19,21,24) have mixed types. Specify dtype
option on import or set low_memory=False.
  df = pd.read_csv(csv_path,sep=";",header= None)
```

##Visualizar los datos

Podemos utilizar el método dataframe.head() para examinar las primeras cinco filas del dataframe, se utiliza cuando el conjuntos de datos es muy grande y no queremos cargar todo:

[ ]:
```
# Imprimir las primeras cinco filas de un dataframe
df.head()
```

[ ]:

	0	1	2
0	FECHA_LLEGADA	FECHA_TRIAGE	FECHA_INGRESO
1	2023-01-01 01:20:23.853	2023-01-01 01:28:01.847	2023-01-01 01:29:41.210
2	2023-01-01 01:29:46.050	2023-01-01 01:48:03.070	2023-01-01 01:49:40.973
3	2023-01-01 03:15:35.623	2023-01-01 03:23:01.990	2023-01-01 03:23:39.793
4	2023-01-01 05:54:53.563	2023-01-01 06:00:07.943	2023-01-01 06:02:07.320

	3	4	5
0	FECHA_ATENCION	TIEMPO_DGTURNO_A_TRIAGE	TIEMPO_TRIAGE_A_INGRESO
1	2023-01-01 02:00:07.590	0:07:38	0:01:40
2	2023-01-01 02:02:53.663	0:18:17	0:01:37
3	2023-01-01 03:30:21.233	0:07:26	0:00:38
4	2023-01-01 06:26:17.050	0:05:14	0:02:00

	6	7	8
0	TIEMPO_INGRESO_A_CONSULTA	TIEMPO_TOTAL	Tiempo_Minutos_Total
1	0:30:26	0:39:44	39,73
2	0:13:13	0:33:07	33,12
3	0:06:42	0:14:46	14,77
4	0:24:10	0:31:24	31,40

```
                9   …                15               16      17    18   19  \
0  CENTRO_ATENCION  …  RÉGIMEN PACIENTE  NOMBRE_ENTIDAD   MEDICO   AÑO  MES
1               TN  …        SUBSIDIADO           EPSS34   11065  2023    1
2               ME  …        SUBSIDIADO           EPSS34    8861  2023    1
3               UC  …      CONTRIBUTIVO           EPS002    5855  2023    1
4               UC  …        SUBSIDIADO           EPSS34   11072  2023    1

           20    21      22                      23   24
0  DIA_SEMANA  HOUR  Turnos                    TIME  DIA
1     DOMINGO     1   NOCHE  2023-01-01 01:20:23.853    1
2     DOMINGO     1   NOCHE  2023-01-01 01:29:46.050    1
3     DOMINGO     3   NOCHE  2023-01-01 03:15:35.623    1
4     DOMINGO     5   NOCHE  2023-01-01 05:54:53.563    1

[5 rows x 25 columns]
```

Después de leer el conjunto de datos podemos utilizar el método dataframe.head(n) para revisar las primeras n filas del dataframe; donde n es un entero. Al contrario de dataframe.head(n), dataframe.tail(n) mostrará las n filas del final del dataframe.

AHORA TÚ:

Revise las ultimas 10 filas del dataframe “df”:

[ ]:
```
# Escribe tu código aquí y presiona Shift+Enter para ejecutar
print("The last 10 rows of the dataframe\n")
df.tail(10)
```

```
The last 10 rows of the dataframe
```

[ ]:
```
                           0                       1   \
82407  2023-09-17 18:12:40.660  2023-09-17 18:43:16.430
82408  2023-09-17 18:52:28.640  2023-09-17 19:48:17.070
82409  2023-09-17 19:57:56.033  2023-09-17 20:15:56.793
82410  2023-09-17 20:22:04.970  2023-09-17 20:36:16.703
82411  2023-09-17 21:22:59.137  2023-09-17 21:42:20.273
82412  2023-09-18 04:44:41.970  2023-09-18 04:53:22.553
82413  2023-09-18 06:17:00.573  2023-09-18 06:28:43.040
82414  2023-09-18 06:21:37.273  2023-09-18 07:00:57.420
82415  2023-09-18 06:25:33.483  2023-09-18 06:42:02.883
82416  2023-09-18 07:14:58.180  2023-09-18 07:30:50.643

                           2                       3        4        5   \
82407  2023-09-17 18:48:36.403  2023-09-17 19:40:11.800  0:30:36  0:05:20
82408  2023-09-17 19:49:47.657  2023-09-17 20:32:54.070  0:55:49  0:01:30
82409  2023-09-17 20:28:57.590  2023-09-17 20:46:29.250  0:18:00  0:13:01
```

```
82410  2023-09-17 20:41:12.783  2023-09-17 22:00:50.287  0:14:12  0:04:56
82411  2023-09-17 21:51:04.433  2023-09-17 22:43:13.710  0:19:21  0:08:44
82412  2023-09-18 05:05:51.423  2023-09-18 06:09:35.867  0:08:41  0:12:29
82413  2023-09-18 06:35:38.213  2023-09-18 07:40:45.957  0:11:43  0:06:55
82414  2023-09-18 07:16:45.907  2023-09-18 08:27:27.337  0:39:20  0:15:48
82415  2023-09-18 06:51:35.970  2023-09-18 07:28:28.290  0:16:29  0:09:33
82416  2023-09-18 07:34:08.370  2023-09-18 07:49:18.440  0:15:52  0:03:18

            6        7       8   9   …            15      16     17    18  \
82407  0:51:35  1:27:31   87,52  ME  …  CONTRIBUTIVO  EPS005    120  2023
82408  0:43:07  1:40:26  100,43  ME  …     SUBSIDIADO  EPSS17    120  2023
82409  0:17:32  0:48:33   48,55  UC  …     SUBSIDIADO  EPSC34   3818  2023
82410  1:19:38  1:38:46   98,77  ME  …     SUBSIDIADO  EPSS02  10786  2023
82411  0:52:09  1:20:14   80,23  ME  …      VINCULADO   11000  10786  2023
82412  1:03:44  1:24:54   84,90  ME  …  CONTRIBUTIVO  EPS017   7844  2023
82413  1:05:07  1:23:45   83,75  ME  …     SUBSIDIADO  EPSC34   6204  2023
82414  1:10:42  2:05:50  125,83  ME  …  CONTRIBUTIVO  EPS041   9951  2023
82415  0:36:53  1:02:55   62,92  UB  …     SUBSIDIADO  EPSC34   4030  2023
82416  0:15:10  0:34:20   34,33  TN  …     SUBSIDIADO  EPSC34   1239  2023

      19       20  21      22                      23  24
82407  9  DOMINGO  18   TARDE  2023-09-17 18:12:40.660  17
82408  9  DOMINGO  18   TARDE  2023-09-17 18:52:28.640  17
82409  9  DOMINGO  19   TARDE  2023-09-17 19:57:56.033  17
82410  9  DOMINGO  20   NOCHE  2023-09-17 20:22:04.970  17
82411  9  DOMINGO  21   NOCHE  2023-09-17 21:22:59.137  17
82412  9    LUNES   4   NOCHE  2023-09-18 04:44:41.970  18
82413  9    LUNES   6   NOCHE  2023-09-18 06:17:00.573  18
82414  9    LUNES   6   NOCHE  2023-09-18 06:21:37.273  18
82415  9    LUNES   6   NOCHE  2023-09-18 06:25:33.483  18
82416  9    LUNES   7  MAÑANA  2023-09-18 07:14:58.180  18

[10 rows x 25 columns]
```

###Añadir cabeceras

Observe el conjunto de datos; Pandas automaticamente establece la cabecera en un entero a partir de 0.
Para describir mejor nuestros datos podemos agregarle una cabecera, esta información esta disponible en: https://archive.ics.uci.edu/ml/datasets/Automobile

De este modo debemos agregar las cabeceras manualmente.
Primero creamos una lista headers que incluya todos los nombres de columna en orden. Despues usamos dataframe.columns = headers para reemplazar las cabeceras por la lista que hemos creado.

[ ]:
```
# crear la lista headers
headers =␣
  ↪["FECHA_LLEGADA","FECHA_TRIAGE","FECHA_INGRESO","FECHA_ATENCION","TIEMPO_DGTURNO_A_TRIAGE",
```

```
␣
↪"CENTRO_ATENCION","CLASIFICACION_TRIAGE","PACIENTE_#_DOCUMENTO","EDAD","EDAD_RANGO","SEXO",
↪PACIENTE","NOMBRE_ENTIDAD","MEDICO","AÑO","MES","DIA_SEMANA","HOUR","Turnos","TIME","DIA"]
print("headers\n", headers)
```

```
headers
 ['FECHA_LLEGADA', 'FECHA_TRIAGE', 'FECHA_INGRESO', 'FECHA_ATENCION',
'TIEMPO_DGTURNO_A_TRIAGE', 'TIEMPO_TRIAGE_A_INGRESO',
'TIEMPO_INGRESO_A_CONSULTA', 'TIEMPO_TOTAL', 'Tiempo_Minutos_Total',
'CENTRO_ATENCION', 'CLASIFICACION_TRIAGE', 'PACIENTE_#_DOCUMENTO', 'EDAD',
'EDAD_RANGO', 'SEXO', 'RÉGIMEN PACIENTE', 'NOMBRE_ENTIDAD', 'MEDICO', 'AÑO',
'MES', 'DIA_SEMANA', 'HOUR', 'Turnos', 'TIME', 'DIA']
```

Remplazamos las cabeceras y volvemos a revisar nuestro dataframe:

[ ]:
```
df.columns = headers
df.head()
```

Acceder a una columna y ver sus valores

Se accede a una columna especificando el nombre de la misma. Por ejemplo, puedes acceder a la columna symboling y a la columna body-style. Cada una de estas columnas es una serie de Pandas.

[ ]:
```
x=df[["PACIENTE_#_DOCUMENTO"]]
x
```

[ ]:
```
       PACIENTE_#_DOCUMENTO
0      PACIENTE_#_DOCUMENTO
1                1007228378
2                1000003681
3                1007454009
4                1022997183
…                       …
82412            1010242518
82413              93357619
82414              41372387
82415            1000807249
82416               4497020

[82417 rows x 1 columns]
```

[ ]:
```
y=df[["Tiempo_Minutos_Total"]]
y
```

[ ]:
```
       Tiempo_Minutos_Total
0      Tiempo_Minutos_Total
1                     39,73
2                     33,12
3                     14,77
```

```
4                    31,40
…                    …
82412                84,90
82413                83,75
82414               125,83
82415                62,92
82416                34,33

[82417 rows x 1 columns]
```

##Tipos de datos

Los datos se encuentran en una variedad de tipos. Los tipos principales almacenados en dataframes de Pandas son object, float, int, bool y datetime64. Para aprender mejor acerca de cada atributo es mejor para nosotros saber el tipo de dato de cada columna.

[ ]:
```
#La función dtypes genera una tabla con el tipo de dato de cada columna
df.dtypes
```

[ ]:
```
FECHA_LLEGADA                object
FECHA_TRIAGE                 object
FECHA_INGRESO                object
FECHA_ATENCION               object
TIEMPO_DGTURNO_A_TRIAGE      object
TIEMPO_TRIAGE_A_INGRESO      object
TIEMPO_INGRESO_A_CONSULTA    object
TIEMPO_TOTAL                 object
Tiempo_Minutos_Total         object
CENTRO_ATENCION              object
CLASIFICACION_TRIAGE         object
PACIENTE_#_DOCUMENTO         object
EDAD                         object
EDAD_RANGO                   object
SEXO                         object
RÉGIMEN PACIENTE             object
NOMBRE_ENTIDAD               object
MEDICO                       object
AÑO                          object
MES                          object
DIA_SEMANA                   object
HOUR                         object
Turnos                       object
TIME                         object
DIA                          object
dtype: object
```

Tipo de dato de una columna específica

De esta forma podemos consultar cuál es el tipo de dato de una columna específica:

[ ]:
```
#Separamos la columna en una dataframe llamado df_column
df_column=df[['Turnos']]
df_column.dtypes
```

[ ]:
```
Turnos    object
dtype: object
```

Cambiar el tipo de dato de una columna específica

¿Cómo cambiar el tipo de dato de una columna específica? Cambiemos el tipo de datos de la columna Price que fue identificado como object y es un float.

[ ]:
```
#utilizamos errors='coerce' para ignorar los datos faltantes
# df["price"] = pd.to_numeric(df["price"],errors='coerce')

df['Turnos'] = df['Turnos'].astype('category')
df['DIA_SEMANA'] = df['DIA_SEMANA'].astype('category')
df['CENTRO_ATENCION'] = df['CENTRO_ATENCION'].astype('category')
df.dtypes
```

[ ]:
```
FECHA_LLEGADA                 object
FECHA_TRIAGE                  object
FECHA_INGRESO                 object
FECHA_ATENCION                object
TIEMPO_DGTURNO_A_TRIAGE       object
TIEMPO_TRIAGE_A_INGRESO       object
TIEMPO_INGRESO_A_CONSULTA     object
TIEMPO_TOTAL                  object
Tiempo_Minutos_Total          object
CENTRO_ATENCION             category
CLASIFICACION_TRIAGE          object
PACIENTE_#_DOCUMENTO          object
EDAD                          object
EDAD_RANGO                    object
SEXO                          object
RÉGIMEN PACIENTE              object
NOMBRE_ENTIDAD                object
MEDICO                        object
AÑO                           object
MES                           object
DIA_SEMANA                  category
HOUR                          object
Turnos                      category
TIME                          object
DIA                           object
dtype: object
```

Como se muestra, se observa claramente que el tipo de dato de symboling y curb-weight es int64,

normalized-losses es object pero debería ser de tipo numérico, al igual que bore, etc. Estos tipos de datos pueden modificarse.

AHORA TÚ:

Cambie el tipo de datos de la columna "stroke":

[ ]:
```
# Escribe tu código aquí y presiona Shift+Enter para ejecutar

df['Tiempo_Total'] = df['Tiempo_Minutos_Total'].str.replace(',', '.',␣
↪regex=True)
df['Tiempo_Total'] = pd.to_numeric(df['Tiempo_Total'], errors='coerce')
```

##Visualizar las estadísticas

Este conjunto de datos es pequeño, pero si se quisiera saber la cantidad de atributos y de elementos que se tienen en el conjunto de datos, se puede utilizar la función dataframe.shape. Esta función visualiza primero el número de elementos y luego el número de atributos.

[ ]:
```
df.shape
```

[ ]:
```
(82417, 26)
```

Vamos a utilizar la función dataframe.describe para visualizar las estadísticas del conjunto de datos. Por defecto, la función dataframe.describe muestra las filas y columnas que contienen números.

Esto mostrará:

el recuento de esa variable

la media

la desviación estándar (std)

el valor mínimo

el IQR (rango intercuartil: 25%, 50% y 75%)

el valor máximo

[ ]:
```
df.describe()
```

[ ]:
```
       Tiempo_Total
count  82416.000000
mean     108.346035
std      132.899154
min        8.570000
25%       60.600000
50%       84.200000
75%      117.672500
max     2684.830000
```

Si se quisiera calcular la mediana de una variable en específico se puede de la siguiente manera:

[ ]:
```
import matplotlib.pyplot as plt
import seaborn as sns
sns.distplot(df["Tiempo_Total"])
```

[ ]:
```
df.head()
```

[ ]:
```
             FECHA_LLEGADA             FECHA_TRIAGE            FECHA_INGRESO  \
1  2023-01-01 01:20:23.853  2023-01-01 01:28:01.847  2023-01-01 01:29:41.210
2  2023-01-01 01:29:46.050  2023-01-01 01:48:03.070  2023-01-01 01:49:40.973
3  2023-01-01 03:15:35.623  2023-01-01 03:23:01.990  2023-01-01 03:23:39.793
4  2023-01-01 05:54:53.563  2023-01-01 06:00:07.943  2023-01-01 06:02:07.320
5  2023-01-01 06:37:27.237  2023-01-01 07:52:31.687  2023-01-01 07:52:37.717

            FECHA_ATENCION TIEMPO_DGTURNO_A_TRIAGE TIEMPO_TRIAGE_A_INGRESO  \
1  2023-01-01 02:00:07.590                0:07:38                 0:01:40
2  2023-01-01 02:02:53.663                0:18:17                 0:01:37
3  2023-01-01 03:30:21.233                0:07:26                 0:00:38
4  2023-01-01 06:26:17.050                0:05:14                 0:02:00
5  2023-01-01 09:31:15.597                1:15:04                 0:00:06

  TIEMPO_INGRESO_A_CONSULTA TIEMPO_TOTAL Tiempo_Minutos_Total CENTRO_ATENCION  \
1                   0:30:26      0:39:44               39,73             TN
2                   0:13:13      0:33:07               33,12             ME
3                   0:06:42      0:14:46               14,77             UC
4                   0:24:10      0:31:24               31,40             UC
5                   1:38:38      2:53:48              173,80             TN

   … NOMBRE_ENTIDAD MEDICO   AÑO MES DIA_SEMANA HOUR Turnos  \
1  …         EPSS34  11065  2023   1    DOMINGO    1  NOCHE
2  …         EPSS34   8861  2023   1    DOMINGO    1  NOCHE
3  …         EPS002   5855  2023   1    DOMINGO    3  NOCHE
4  …         EPSS34  11072  2023   1    DOMINGO    5  NOCHE
5  …         EPSS34   1239  2023   1    DOMINGO    6  NOCHE

                     TIME DIA Tiempo_Total
1  2023-01-01 01:20:23.853   1        39.73
2  2023-01-01 01:29:46.050   1        33.12
3  2023-01-01 03:15:35.623   1        14.77
4  2023-01-01 05:54:53.563   1        31.40
5  2023-01-01 06:37:27.237   1       173.80

[5 rows x 26 columns]
```

[ ]:
```
df = df.drop(0)
```

[ ]:
```
#Muestra la mediana para los atributos "length" y "compression-ratio"
median= df[['Tiempo_Total']].median()
```

```
median
```

```
Tiempo_Total    84.2
dtype: float64
```

Por defecto la función solo muestra atributos que son numéricos. Es posible hacer que la función describe funcione también para las columnas de tipo object. Para permitir un resumen de todas las columnas, podríamos añadir un argumento include="all" entre los paréntesis de la función describe.

```
#unique, top y frequency ("único, superior y frecuencia").
#df.describe(include="object")
df.describe(include="all")
```

```
                  FECHA_LLEGADA             FECHA_TRIAGE  \
count                     82416                    82416
unique                    80382                    80388
top     2023-08-06 14:31:20.657  2023-08-04 11:13:29.903
freq                          4                        4
mean                        NaN                      NaN
std                         NaN                      NaN
min                         NaN                      NaN
25%                         NaN                      NaN
50%                         NaN                      NaN
75%                         NaN                      NaN
max                         NaN                      NaN

                  FECHA_INGRESO           FECHA_ATENCION  \
count                     82416                    82416
unique                    80387                    82414
top     2023-05-05 16:30:25.897  2023-03-29 21:49:44.440
freq                          4                        2
mean                        NaN                      NaN
std                         NaN                      NaN
min                         NaN                      NaN
25%                         NaN                      NaN
50%                         NaN                      NaN
75%                         NaN                      NaN
max                         NaN                      NaN

       TIEMPO_DGTURNO_A_TRIAGE TIEMPO_TRIAGE_A_INGRESO  \
count                    82416                   82416
unique                    5981                    3433
top                     0:10:06                 0:01:08
freq                         72                     218
mean                        NaN                     NaN
std                         NaN                     NaN
min                         NaN                     NaN
```

```
25%                          NaN                    NaN
50%                          NaN                    NaN
75%                          NaN                    NaN
max                          NaN                    NaN

       TIEMPO_INGRESO_A_CONSULTA TIEMPO_TOTAL Tiempo_Minutos_Total  \
count                      82416        82416                82416
unique                     12074        13866                14141
top                      0:33:27      1:13:04                73,07
freq                          37           28                   28
mean                         NaN          NaN                  NaN
std                          NaN          NaN                  NaN
min                          NaN          NaN                  NaN
25%                          NaN          NaN                  NaN
50%                          NaN          NaN                  NaN
75%                          NaN          NaN                  NaN
max                          NaN          NaN                  NaN

       CENTRO_ATENCION  …  NOMBRE_ENTIDAD   MEDICO      AÑO      MES  \
count            82416  …           82416  82416.0  82416.0  82416.0
unique               9  …              78    378.0      2.0     14.0
top                 ME  …          EPSC34   3826.0   2023.0      7.0
freq             41221  …           45973   1464.0  49649.0  10108.0
mean               NaN  …             NaN      NaN      NaN      NaN
std                NaN  …             NaN      NaN      NaN      NaN
min                NaN  …             NaN      NaN      NaN      NaN
25%                NaN  …             NaN      NaN      NaN      NaN
50%                NaN  …             NaN      NaN      NaN      NaN
75%                NaN  …             NaN      NaN      NaN      NaN
max                NaN  …             NaN      NaN      NaN      NaN

       DIA_SEMANA     HOUR  Turnos                       TIME      DIA  \
count       82416  82416.0   82416                      82416  82416.0
unique          7     48.0       3                      80382     62.0
top         LUNES     10.0  MAÑANA  2023-08-06 14:31:20.657      8.0
freq        13390   3911.0   40363                          4   2040.0
mean          NaN      NaN     NaN                        NaN      NaN
std           NaN      NaN     NaN                        NaN      NaN
min           NaN      NaN     NaN                        NaN      NaN
25%           NaN      NaN     NaN                        NaN      NaN
50%           NaN      NaN     NaN                        NaN      NaN
75%           NaN      NaN     NaN                        NaN      NaN
max           NaN      NaN     NaN                        NaN      NaN

        Tiempo_Total
count   82416.000000
unique           NaN
```

```
top              NaN
freq             NaN
mean      108.346035
std       132.899154
min         8.570000
25%        60.600000
50%        84.200000
75%       117.672500
max      2684.830000

[11 rows x 26 columns]
```

Contar Valores

Una forma de resumir los datos categóricos es usando la función value_counts. Por ejemplo, en nuestro conjunto de datos, tenemos el lugar del motor (engine-location) como una variable categórica de frontal y trasero.

[ ]:
```
drive_wheels_counts = df['Turnos'].value_counts().to_frame()
drive_wheels_counts
```

[ ]:
```
         count
Turnos
MAÑANA   40363
TARDE    25052
NOCHE    17001
Turnos       0
```

Examinar los recuentos de valores de la ubicación del motor no sería una buena variable predictiva del precio. Esto se debe a que solo tenemos tres autos con motor trasero y 202 con motor delantero, este resultado es sesgado. Por lo tanto, no podemos sacar ninguna conclusión sobre la ubicación del motor.

AHORA TÚ:

Puede seleccionar las columna de un dataframe indicando el nombre de cada una, por ejemplo, puede seleccionar tres columnas de la siguiente manera:

dataframe[[‘column 1’,column 2’, ‘column 3’]]

Donde “column” es el nombre de la columna se puede aplicar el método “.describe()” para obtener las estadísticas de aquellas columnas de la siguiente manera:

dataframe[[’ column 1 ‘,column 2’, ‘column 3’]].describe()

Aplicar el método “.describe()” a las columnas ‘length’ y ‘compression-ratio’.

[ ]:
```
# Escribe tu código aquí y presiona Shift+Enter para ejecutar
df[['DIA_SEMANA', 'Turnos','Tiempo_Total']].describe()
```

[ ]:
```
       Tiempo_Total
count  82416.000000
mean     108.346035
std      132.899154
min        8.570000
25%       60.600000
50%       84.200000
75%      117.672500
max     2684.830000
```

##Identificar datos faltantes

Debemos visualizar nuestros datos e identificar el valor(es) que se está utilizando para los datos faltantes. Los valores faltantes pueden ser espacios vacíos, NA, n/a, –, 0, o cualquier otro valor que no es considerado correcto en esa columna.

[ ]:
```
#Identifique cual es el valor que se está utilizando para los datos faltantes␣
↪en el set de datos:
df.head(20)
```

[ ]:
```
              FECHA_LLEGADA             FECHA_TRIAGE            FECHA_INGRESO  \
1   2023-01-01 01:20:23.853  2023-01-01 01:28:01.847  2023-01-01 01:29:41.210
2   2023-01-01 01:29:46.050  2023-01-01 01:48:03.070  2023-01-01 01:49:40.973
3   2023-01-01 03:15:35.623  2023-01-01 03:23:01.990  2023-01-01 03:23:39.793
4   2023-01-01 05:54:53.563  2023-01-01 06:00:07.943  2023-01-01 06:02:07.320
5   2023-01-01 06:37:27.237  2023-01-01 07:52:31.687  2023-01-01 07:52:37.717
6   2023-01-01 07:09:46.950  2023-01-01 07:18:01.200  2023-01-01 07:20:03.720
7   2023-01-01 07:20:31.113  2023-01-01 07:27:36.230  2023-01-01 07:34:17.667
8   2023-01-01 07:53:52.963  2023-01-01 08:01:10.640  2023-01-01 08:03:13.710
9   2023-01-01 08:05:21.230  2023-01-01 08:53:07.870  2023-01-01 08:56:10.277
10  2023-01-01 09:24:15.530  2023-01-01 09:52:05.463  2023-01-01 09:59:19.673
11  2023-01-01 10:57:35.917  2023-01-01 11:26:37.567  2023-01-01 11:30:19.197
12  2023-01-01 14:34:37.470  2023-01-01 14:49:51.770  2023-01-01 15:02:04.030
13  2023-01-01 14:54:22.407  2023-01-01 15:13:27.167  2023-01-01 15:20:55.660
14  2023-01-01 14:56:15.033  2023-01-01 15:03:35.823  2023-01-01 15:04:17.987
15  2023-01-01 16:09:09.527  2023-01-01 16:14:42.000  2023-01-01 16:16:22.767
16  2023-01-01 18:07:03.087  2023-01-01 18:23:37.837  2023-01-01 18:24:11.420
17  2023-01-01 18:13:00.330  2023-01-01 18:31:06.813  2023-01-01 18:34:41.503
18  2023-01-02 03:34:19.883  2023-01-02 03:56:47.470  2023-01-02 03:57:22.443
19  2023-01-02 04:30:07.617  2023-01-02 05:36:52.657  2023-01-02 05:38:34.253
20  2023-01-02 06:27:33.233  2023-01-02 07:12:56.400  2023-01-02 07:13:07.473

              FECHA_ATENCION TIEMPO_DGTURNO_A_TRIAGE TIEMPO_TRIAGE_A_INGRESO  \
1   2023-01-01 02:00:07.590                0:07:38                0:01:40
2   2023-01-01 02:02:53.663                0:18:17                0:01:37
3   2023-01-01 03:30:21.233                0:07:26                0:00:38
4   2023-01-01 06:26:17.050                0:05:14                0:02:00
5   2023-01-01 09:31:15.597                1:15:04                0:00:06
```

```
6   2023-01-01 07:48:42.197                0:08:15                0:02:02
7   2023-01-01 07:59:17.140                0:07:05                0:06:41
8   2023-01-01 08:43:09.917                0:07:18                0:02:03
9   2023-01-01 09:26:52.977                0:47:46                0:03:03
10  2023-01-01 10:38:12.297                0:27:50                0:07:14
11  2023-01-01 12:48:10.377                0:29:02                0:03:42
12  2023-01-01 16:33:36.400                0:15:14                0:12:13
13  2023-01-01 16:47:10.060                0:19:05                0:07:28
14  2023-01-01 16:12:09.400                0:07:20                0:00:42
15  2023-01-01 16:39:18.937                0:05:33                0:01:40
16  2023-01-01 19:33:28.253                0:16:34                0:00:34
17  2023-01-01 19:54:53.770                0:18:06                0:03:35
18  2023-01-02 04:49:21.190                0:22:28                0:00:35
19  2023-01-02 05:54:41.813                1:06:45                0:01:42
20  2023-01-02 07:21:55.423                0:45:23                0:00:11

   TIEMPO_INGRESO_A_CONSULTA TIEMPO_TOTAL Tiempo_Minutos_Total  \
1                    0:30:26      0:39:44                39,73
2                    0:13:13      0:33:07                33,12
3                    0:06:42      0:14:46                14,77
4                    0:24:10      0:31:24                31,40
5                    1:38:38      2:53:48               173,80
6                    0:28:39      0:38:56                38,93
7                    0:25:00      0:38:46                38,77
8                    0:39:56      0:49:17                49,28
9                    0:30:42      1:21:31                81,52
10                   0:38:53      1:13:57                73,95
11                   1:17:51      1:50:35               110,58
12                   1:31:32      1:58:59               118,98
13                   1:26:15      1:52:48               112,80
14                   1:07:52      1:15:54                75,90
15                   0:22:56      0:30:09                30,15
16                   1:09:17      1:26:25                86,42
17                   1:20:12      1:41:53               101,88
18                   0:51:59      1:15:02                75,03
19                   0:16:07      1:24:34                84,57
20                   0:08:48      0:54:22                54,37

   CENTRO_ATENCION  … NOMBRE_ENTIDAD MEDICO   AÑO MES DIA_SEMANA HOUR  \
1               TN  …         EPSS34  11065  2023   1    DOMINGO    1
2               ME  …         EPSS34   8861  2023   1    DOMINGO    1
3               UC  …         EPS002   5855  2023   1    DOMINGO    3
4               UC  …         EPSS34  11072  2023   1    DOMINGO    5
5               TN  …         EPSS34   1239  2023   1    DOMINGO    6
6               VB  …         EPS005  10751  2023   1    DOMINGO    7
7               UC  …         EPSS34  11072  2023   1    DOMINGO    7
8               VB  …         EPS041  10795  2023   1    DOMINGO    7
```

```
9              UB  …         ESS207   7795  2023   1    DOMINGO    8
10             ME  …         EPSS34    120  2023   1    DOMINGO    9
11             ME  …         EPSS17   7551  2023   1    DOMINGO   10
12             ME  …         ESS024   6204  2023   1    DOMINGO   14
13             VB  …         EPSS34   3826  2023   1    DOMINGO   14
14             VB  …         EPSS34  10795  2023   1    DOMINGO   14
15             TN  …         EPSC34   1239  2023   1    DOMINGO   16
16             TN  …         EPSS34  10030  2023   1    DOMINGO   18
17             TN  …         EPSS05  10030  2023   1    DOMINGO   18
18             ME  …         EPS002  10938  2023   1      LUNES    3
19             JT  …         EPSS34   8373  2023   1      LUNES    4
20             ME  …         EPSC34   4610  2023   1      LUNES    6

    Turnos                       TIME DIA Tiempo_Total
1    NOCHE  2023-01-01 01:20:23.853   1        39.73
2    NOCHE  2023-01-01 01:29:46.050   1        33.12
3    NOCHE  2023-01-01 03:15:35.623   1        14.77
4    NOCHE  2023-01-01 05:54:53.563   1        31.40
5    NOCHE  2023-01-01 06:37:27.237   1       173.80
6   MAÑANA  2023-01-01 07:09:46.950   1        38.93
7   MAÑANA  2023-01-01 07:20:31.113   1        38.77
8   MAÑANA  2023-01-01 07:53:52.963   1        49.28
9   MAÑANA  2023-01-01 08:05:21.230   1        81.52
10  MAÑANA  2023-01-01 09:24:15.530   1        73.95
11  MAÑANA  2023-01-01 10:57:35.917   1       110.58
12   TARDE  2023-01-01 14:34:37.470   1       118.98
13   TARDE  2023-01-01 14:54:22.407   1       112.80
14   TARDE  2023-01-01 14:56:15.033   1        75.90
15   TARDE  2023-01-01 16:09:09.527   1        30.15
16   TARDE  2023-01-01 18:07:03.087   1        86.42
17   TARDE  2023-01-01 18:13:00.330   1       101.88
18   NOCHE  2023-01-02 03:34:19.883   2        75.03
19   NOCHE  2023-01-02 04:30:07.617   2        84.57
20   NOCHE  2023-01-02 06:27:33.233   2        54.37

[20 rows x 26 columns]
```

Con la función isnull podemos saber cuantos datos faltantes identifica Python en nuestro set de datos.

[ ]:
```
print(df.isnull().sum())
```

```
FECHA_LLEGADA               0
FECHA_TRIAGE                0
FECHA_INGRESO               0
FECHA_ATENCION              0
TIEMPO_DGTURNO_A_TRIAGE     0
TIEMPO_TRIAGE_A_INGRESO     0
```

```
TIEMPO_INGRESO_A_CONSULTA    0
TIEMPO_TOTAL                 0
Tiempo_Minutos_Total         0
CENTRO_ATENCION              0
CLASIFICACION_TRIAGE         0
PACIENTE_#_DOCUMENTO         0
EDAD                         0
EDAD_RANGO                   0
SEXO                         0
RÉGIMEN PACIENTE             0
NOMBRE_ENTIDAD               0
MEDICO                       0
AÑO                          0
MES                          0
DIA_SEMANA                   0
HOUR                         0
Turnos                       0
TIME                         0
DIA                          0
Tiempo_Total                 0
dtype: int64
```

Todavía Python no está identificando los datos faltantes en el conjunto de datos, sino que los está tratando como un valor correcto más. Para marcar los datos faltantes se realiza los siguiente:

[ ]:
```
#Realice una lista de los valores que son identificados como datos faltantes
#No olvide al final volver a cargar las cabeceras
missing_values = ["?", "1"]
csv_path = 'ind_urgencias_final_2023_filtrado.txt'
df = pd.read_csv(csv_path,sep=";",header= None, na_values = missing_values)
df.head(20)
```

```
C:\Users\Victor.Gomez\AppData\Local\Temp\ipykernel_14576\2949932682.py:5:
DtypeWarning: Columns (10,12,17,18,19,21,24) have mixed types. Specify dtype
option on import or set low_memory=False.
  df = pd.read_csv(csv_path,sep=";",header= None, na_values = missing_values)
```

[ ]:

	0	1	2	\
0	FECHA_LLEGADA	FECHA_TRIAGE	FECHA_INGRESO	
1	2023-01-01 01:20:23.853	2023-01-01 01:28:01.847	2023-01-01 01:29:41.210	
2	2023-01-01 01:29:46.050	2023-01-01 01:48:03.070	2023-01-01 01:49:40.973	
3	2023-01-01 03:15:35.623	2023-01-01 03:23:01.990	2023-01-01 03:23:39.793	
4	2023-01-01 05:54:53.563	2023-01-01 06:00:07.943	2023-01-01 06:02:07.320	
5	2023-01-01 06:37:27.237	2023-01-01 07:52:31.687	2023-01-01 07:52:37.717	
6	2023-01-01 07:09:46.950	2023-01-01 07:18:01.200	2023-01-01 07:20:03.720	
7	2023-01-01 07:20:31.113	2023-01-01 07:27:36.230	2023-01-01 07:34:17.667	
8	2023-01-01 07:53:52.963	2023-01-01 08:01:10.640	2023-01-01 08:03:13.710	
9	2023-01-01 08:05:21.230	2023-01-01 08:53:07.870	2023-01-01 08:56:10.277	

10	2023-01-01 09:24:15.530	2023-01-01 09:52:05.463	2023-01-01 09:59:19.673
11	2023-01-01 10:57:35.917	2023-01-01 11:26:37.567	2023-01-01 11:30:19.197
12	2023-01-01 14:34:37.470	2023-01-01 14:49:51.770	2023-01-01 15:02:04.030
13	2023-01-01 14:54:22.407	2023-01-01 15:13:27.167	2023-01-01 15:20:55.660
14	2023-01-01 14:56:15.033	2023-01-01 15:03:35.823	2023-01-01 15:04:17.987
15	2023-01-01 16:09:09.527	2023-01-01 16:14:42.000	2023-01-01 16:16:22.767
16	2023-01-01 18:07:03.087	2023-01-01 18:23:37.837	2023-01-01 18:24:11.420
17	2023-01-01 18:13:00.330	2023-01-01 18:31:06.813	2023-01-01 18:34:41.503
18	2023-01-02 03:34:19.883	2023-01-02 03:56:47.470	2023-01-02 03:57:22.443
19	2023-01-02 04:30:07.617	2023-01-02 05:36:52.657	2023-01-02 05:38:34.253

	3	4	5
0	FECHA_ATENCION	TIEMPO_DGTURNO_A_TRIAGE	TIEMPO_TRIAGE_A_INGRESO
1	2023-01-01 02:00:07.590	0:07:38	0:01:40
2	2023-01-01 02:02:53.663	0:18:17	0:01:37
3	2023-01-01 03:30:21.233	0:07:26	0:00:38
4	2023-01-01 06:26:17.050	0:05:14	0:02:00
5	2023-01-01 09:31:15.597	1:15:04	0:00:06
6	2023-01-01 07:48:42.197	0:08:15	0:02:02
7	2023-01-01 07:59:17.140	0:07:05	0:06:41
8	2023-01-01 08:43:09.917	0:07:18	0:02:03
9	2023-01-01 09:26:52.977	0:47:46	0:03:03
10	2023-01-01 10:38:12.297	0:27:50	0:07:14
11	2023-01-01 12:48:10.377	0:29:02	0:03:42
12	2023-01-01 16:33:36.400	0:15:14	0:12:13
13	2023-01-01 16:47:10.060	0:19:05	0:07:28
14	2023-01-01 16:12:09.400	0:07:20	0:00:42
15	2023-01-01 16:39:18.937	0:05:33	0:01:40
16	2023-01-01 19:33:28.253	0:16:34	0:00:34
17	2023-01-01 19:54:53.770	0:18:06	0:03:35
18	2023-01-02 04:49:21.190	0:22:28	0:00:35
19	2023-01-02 05:54:41.813	1:06:45	0:01:42

	6	7	8
0	TIEMPO_INGRESO_A_CONSULTA	TIEMPO_TOTAL	Tiempo_Minutos_Total
1	0:30:26	0:39:44	39,73
2	0:13:13	0:33:07	33,12
3	0:06:42	0:14:46	14,77
4	0:24:10	0:31:24	31,40
5	1:38:38	2:53:48	173,80
6	0:28:39	0:38:56	38,93
7	0:25:00	0:38:46	38,77
8	0:39:56	0:49:17	49,28
9	0:30:42	1:21:31	81,52
10	0:38:53	1:13:57	73,95
11	1:17:51	1:50:35	110,58
12	1:31:32	1:58:59	118,98

13	1:26:15	1:52:48	112,80
14	1:07:52	1:15:54	75,90
15	0:22:56	0:30:09	30,15
16	1:09:17	1:26:25	86,42
17	1:20:12	1:41:53	101,88
18	0:51:59	1:15:02	75,03
19	0:16:07	1:24:34	84,57

	9	…	15	16	17	18	\
0	CENTRO_ATENCION	…	RÉGIMEN PACIENTE	NOMBRE_ENTIDAD	MEDICO	AÑO	
1	TN	…	SUBSIDIADO	EPSS34	11065	2023	
2	ME	…	SUBSIDIADO	EPSS34	8861	2023	
3	UC	…	CONTRIBUTIVO	EPS002	5855	2023	
4	UC	…	SUBSIDIADO	EPSS34	11072	2023	
5	TN	…	SUBSIDIADO	EPSS34	1239	2023	
6	VB	…	CONTRIBUTIVO	EPS005	10751	2023	
7	UC	…	SUBSIDIADO	EPSS34	11072	2023	
8	VB	…	CONTRIBUTIVO	EPS041	10795	2023	
9	UB	…	SUBSIDIADO	ESS207	7795	2023	
10	ME	…	SUBSIDIADO	EPSS34	120	2023	
11	ME	…	CONTRIBUTIVO	EPSS17	7551	2023	
12	ME	…	SUBSIDIADO	ESS024	6204	2023	
13	VB	…	SUBSIDIADO	EPSS34	3826	2023	
14	VB	…	SUBSIDIADO	EPSS34	10795	2023	
15	TN	…	CONTRIBUTIVO	EPSC34	1239	2023	
16	TN	…	SUBSIDIADO	EPSS34	10030	2023	
17	TN	…	SUBSIDIADO	EPSS05	10030	2023	
18	ME	…	CONTRIBUTIVO	EPS002	10938	2023	
19	JT	…	SUBSIDIADO	EPSS34	8373	2023	

	19	20	21	22	23	24
0	MES	DIA_SEMANA	HOUR	Turnos	TIME	DIA
1	1	DOMINGO	1	NOCHE	2023-01-01 01:20:23.853	1
2	1	DOMINGO	1	NOCHE	2023-01-01 01:29:46.050	1
3	1	DOMINGO	3	NOCHE	2023-01-01 03:15:35.623	1
4	1	DOMINGO	5	NOCHE	2023-01-01 05:54:53.563	1
5	1	DOMINGO	6	NOCHE	2023-01-01 06:37:27.237	1
6	1	DOMINGO	7	MAÑANA	2023-01-01 07:09:46.950	1
7	1	DOMINGO	7	MAÑANA	2023-01-01 07:20:31.113	1
8	1	DOMINGO	7	MAÑANA	2023-01-01 07:53:52.963	1
9	1	DOMINGO	8	MAÑANA	2023-01-01 08:05:21.230	1
10	1	DOMINGO	9	MAÑANA	2023-01-01 09:24:15.530	1
11	1	DOMINGO	10	MAÑANA	2023-01-01 10:57:35.917	1
12	1	DOMINGO	14	TARDE	2023-01-01 14:34:37.470	1
13	1	DOMINGO	14	TARDE	2023-01-01 14:54:22.407	1
14	1	DOMINGO	14	TARDE	2023-01-01 14:56:15.033	1
15	1	DOMINGO	16	TARDE	2023-01-01 16:09:09.527	1

```
16    1     DOMINGO    18   TARDE  2023-01-01 18:07:03.087    1
17    1     DOMINGO    18   TARDE  2023-01-01 18:13:00.330    1
18    1       LUNES     3   NOCHE  2023-01-02 03:34:19.883    2
19    1       LUNES     4   NOCHE  2023-01-02 04:30:07.617    2

[20 rows x 25 columns]
```

[ ]:
```
# crear la lista headers

df = df.drop(0)
headers = ␣
  ↪["FECHA_LLEGADA","FECHA_TRIAGE","FECHA_INGRESO","FECHA_ATENCION","TIEMPO_DGTURNO_A_TRIAGE",
          ␣
  ↪"CENTRO_ATENCION","CLASIFICACION_TRIAGE","PACIENTE_#_DOCUMENTO","EDAD","EDAD_RANGO","SEXO",
  ↪PACIENTE","NOMBRE_ENTIDAD","MEDICO","AÑO","MES","DIA_SEMANA","HOUR","Turnos","TIME","DIA"]
df.columns = headers
df.head()
```

[ ]:
```
              FECHA_LLEGADA             FECHA_TRIAGE            FECHA_INGRESO  \
1  2023-01-01 01:20:23.853  2023-01-01 01:28:01.847  2023-01-01 01:29:41.210
2  2023-01-01 01:29:46.050  2023-01-01 01:48:03.070  2023-01-01 01:49:40.973
3  2023-01-01 03:15:35.623  2023-01-01 03:23:01.990  2023-01-01 03:23:39.793
4  2023-01-01 05:54:53.563  2023-01-01 06:00:07.943  2023-01-01 06:02:07.320
5  2023-01-01 06:37:27.237  2023-01-01 07:52:31.687  2023-01-01 07:52:37.717

             FECHA_ATENCION TIEMPO_DGTURNO_A_TRIAGE TIEMPO_TRIAGE_A_INGRESO  \
1  2023-01-01 02:00:07.590                 0:07:38                 0:01:40
2  2023-01-01 02:02:53.663                 0:18:17                 0:01:37
3  2023-01-01 03:30:21.233                 0:07:26                 0:00:38
4  2023-01-01 06:26:17.050                 0:05:14                 0:02:00
5  2023-01-01 09:31:15.597                 1:15:04                 0:00:06

  TIEMPO_INGRESO_A_CONSULTA TIEMPO_TOTAL Tiempo_Minutos_Total CENTRO_ATENCION  \
1                   0:30:26      0:39:44                39,73              TN
2                   0:13:13      0:33:07                33,12              ME
3                   0:06:42      0:14:46                14,77              UC
4                   0:24:10      0:31:24                31,40              UC
5                   1:38:38      2:53:48               173,80              TN

   … RÉGIMEN PACIENTE NOMBRE_ENTIDAD MEDICO   AÑO MES DIA_SEMANA HOUR  \
1  …       SUBSIDIADO         EPSS34  11065  2023   1    DOMINGO    1
2  …       SUBSIDIADO         EPSS34   8861  2023   1    DOMINGO    1
3  …     CONTRIBUTIVO         EPS002   5855  2023   1    DOMINGO    3
4  …       SUBSIDIADO         EPSS34  11072  2023   1    DOMINGO    5
5  …       SUBSIDIADO         EPSS34   1239  2023   1    DOMINGO    6

  Turnos                     TIME DIA
```

```
1  NOCHE  2023-01-01 01:20:23.853   1
2  NOCHE  2023-01-01 01:29:46.050   1
3  NOCHE  2023-01-01 03:15:35.623   1
4  NOCHE  2023-01-01 05:54:53.563   1
5  NOCHE  2023-01-01 06:37:27.237   1

[5 rows x 25 columns]
```

Vuelva a ejectuar la sentencia print(df.isnull().sum()) para visualizar los datos faltantes

[ ]:
```
print(df.isnull().sum())
```

```
FECHA_LLEGADA                0
FECHA_TRIAGE                 0
FECHA_INGRESO                0
FECHA_ATENCION               0
TIEMPO_DGTURNO_A_TRIAGE      0
TIEMPO_TRIAGE_A_INGRESO      0
TIEMPO_INGRESO_A_CONSULTA    0
TIEMPO_TOTAL                 0
Tiempo_Minutos_Total         0
CENTRO_ATENCION              0
CLASIFICACION_TRIAGE         0
PACIENTE_#_DOCUMENTO         0
EDAD                         0
EDAD_RANGO                   0
SEXO                         0
RÉGIMEN PACIENTE             0
NOMBRE_ENTIDAD               0
MEDICO                       0
AÑO                          0
MES                          0
DIA_SEMANA                   0
HOUR                         0
Turnos                       0
TIME                         0
DIA                          0
dtype: int64
```

[ ]:
```
df.dtypes
```

[ ]:
```
FECHA_LLEGADA                object
FECHA_TRIAGE                 object
FECHA_INGRESO                object
FECHA_ATENCION               object
TIEMPO_DGTURNO_A_TRIAGE      object
TIEMPO_TRIAGE_A_INGRESO      object
```

```
TIEMPO_INGRESO_A_CONSULTA      object
TIEMPO_TOTAL                   object
Tiempo_Minutos_Total           object
CENTRO_ATENCION              category
CLASIFICACION_TRIAGE           object
PACIENTE_#_DOCUMENTO           object
EDAD                           object
EDAD_RANGO                     object
SEXO                           object
RÉGIMEN PACIENTE               object
NOMBRE_ENTIDAD                 object
MEDICO                         object
AÑO                            object
MES                             int64
DIA_SEMANA                   category
HOUR                            int64
Turnos                       category
TIME                           object
DIA                             int64
Tiempo_Total                 float64
dtype: object
```

##Explorar relaciones entre los datos

Variables numéricas continuas:

Las variables numéricas continuas son variables que pueden contener cualquier valor dentro de cierto rango. Las variables numéricas continuas pueden tener el tipo int64 o float64. Una excelente manera de visualizar estas variables es mediante el uso de diagramas de dispersión con líneas ajustadas.

Para comenzar a comprender la relación (lineal) entre una variable individual y el precio. Podemos hacer esto usando regplot, que traza el diagrama de dispersión más la línea de regresión ajustada para los datos.

Vamos a importar las librerías Matplotlib y Seaborn para la visualización de datos. Les ponemos un alias plt y sns para que sea más fácil su uso:

[ ]:
```
import matplotlib.pyplot as plt
import seaborn as sns
```

El gráfico seaborn.pairplot permite visualizar todas las variables numéricas y la combinación entre ellas. Pudiendo identificar facilmente si existen relaciones de dependencia entre algunas variables.

[ ]:
```
#sns.pairplot(df)
df['Tiempo_Total'] = df['Tiempo_Minutos_Total'].str.replace(',', '.',␣
 ↪regex=True)
df['Tiempo_Total'] = pd.to_numeric(df['Tiempo_Total'], errors='coerce')
df['Turnos'] = df['Turnos'].astype('category')
df['DIA_SEMANA'] = df['DIA_SEMANA'].astype('category')
```

```
df['CENTRO_ATENCION'] = df['CENTRO_ATENCION'].astype('category')
df['MES'] = pd.to_numeric(df['MES'], errors='coerce')
df['HOUR'] = pd.to_numeric(df['HOUR'], errors='coerce')
df['DIA'] = pd.to_numeric(df['DIA'], errors='coerce')

sub_df = df[['Tiempo_Total','MES', 'DIA','HOUR']]

sns.pairplot(sub_df)
```

```
c:\Users\Victor.Gomez\AppData\Local\Programs\Python\Python311\Lib\site-
packages\seaborn\axisgrid.py:118: UserWarning: The figure layout has changed to
tight
  self._figure.tight_layout(*args, **kwargs)
```

[ ]: <seaborn.axisgrid.PairGrid at 0x1b6b1f7b010>

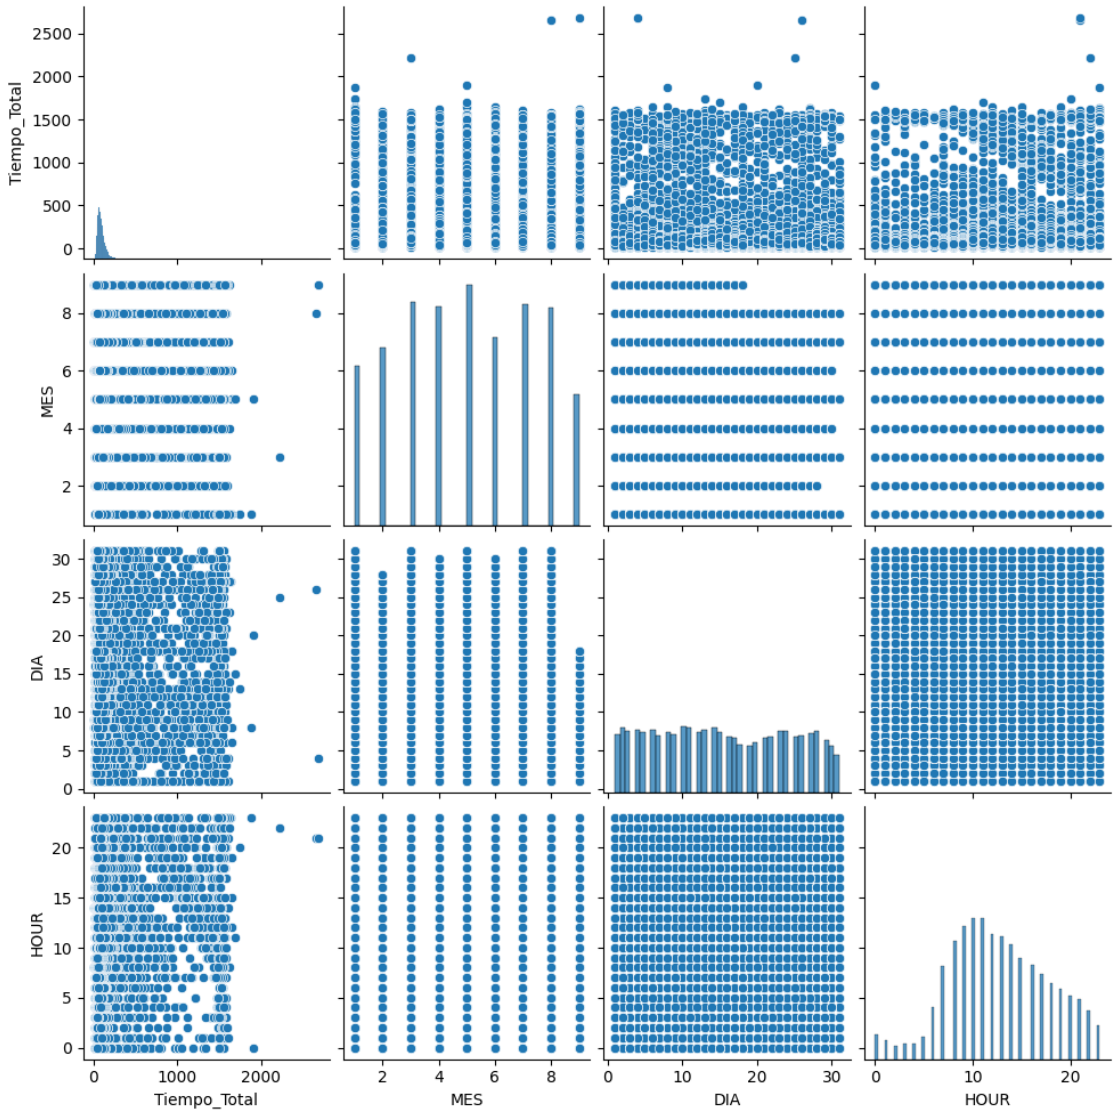

Visualicemos el diagrama de dispersión de tamaño del motor (engine-size) y precio (price)

[ ]:
```
# Luego, crea el gráfico de regresión
sns.set(style="whitegrid")
sns.regplot(x="HOUR", y="Tiempo_Total", data=df)
plt.ylim(0,)
plt.show()
```

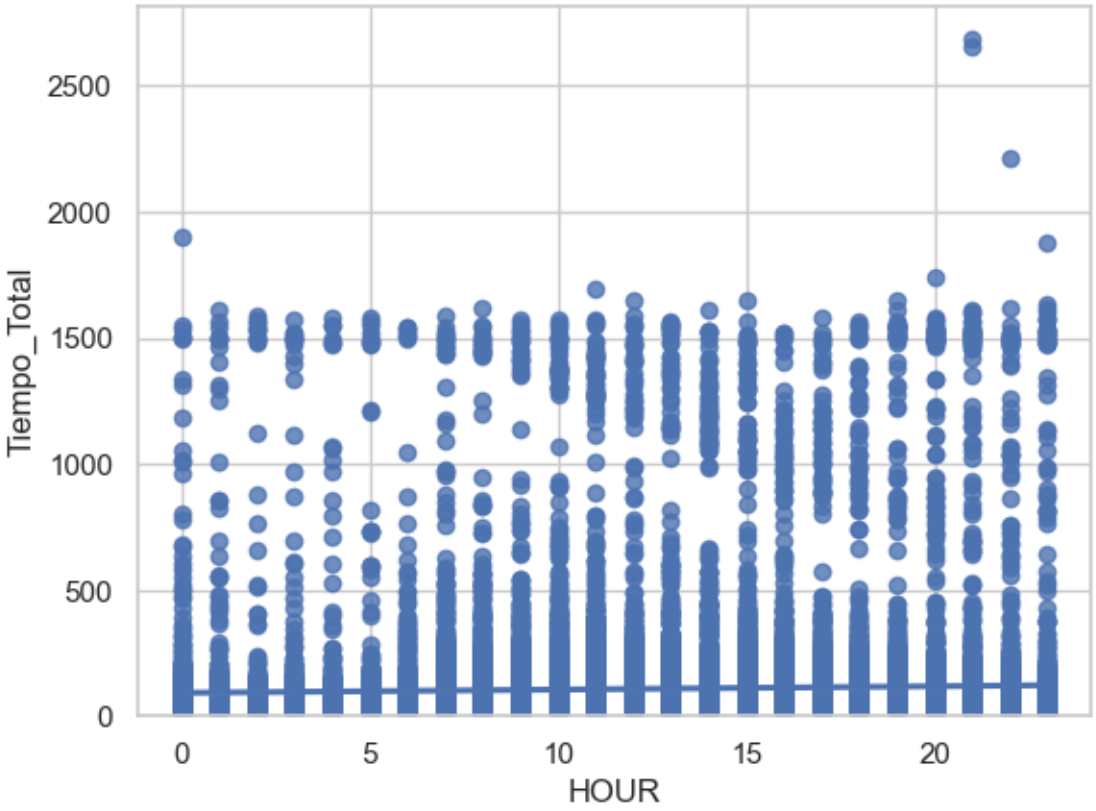

[ ]:
```
# Luego, crea el gráfico de regresión
sns.set(style="whitegrid")
sns.regplot(x="DIA", y="Tiempo_Total", data=df)
plt.ylim(0,)
plt.show()
```

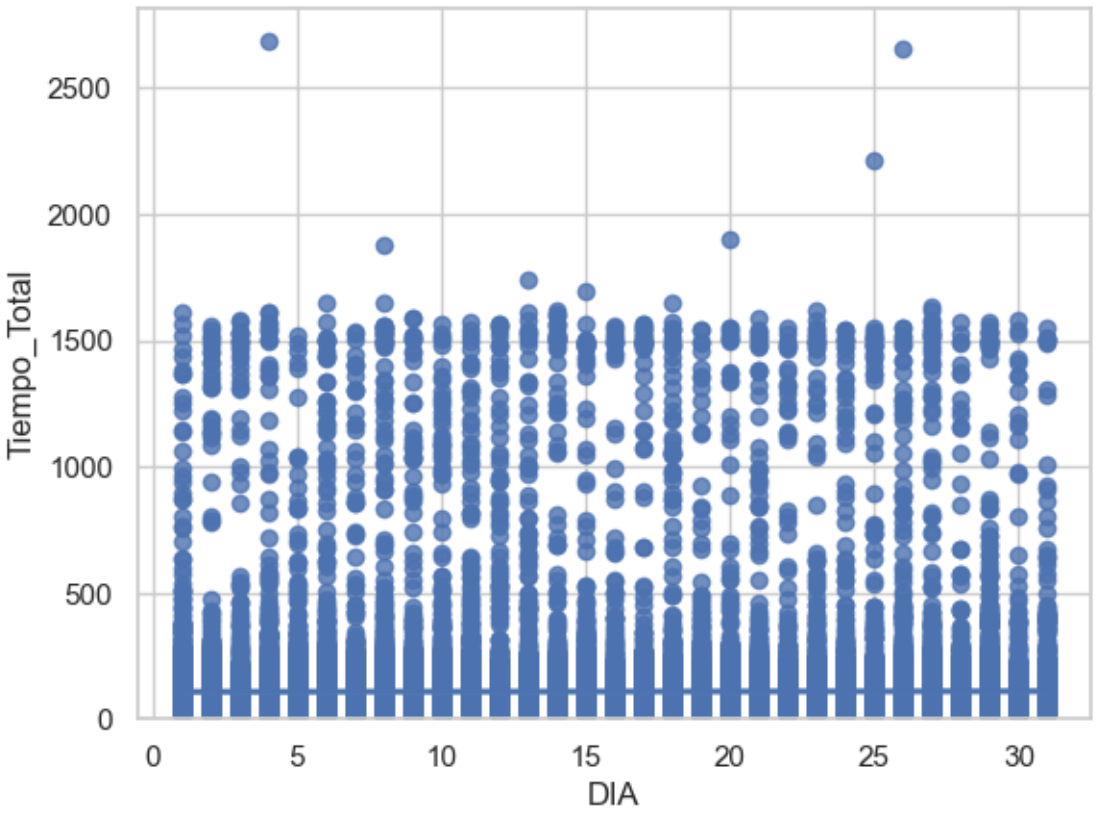

[ ]:
```
# Luego, crea el gráfico de regresión
sns.set(style="whitegrid")
sns.regplot(x="MES", y="Tiempo_Total", data=df)
plt.ylim(0,)
plt.show()
```

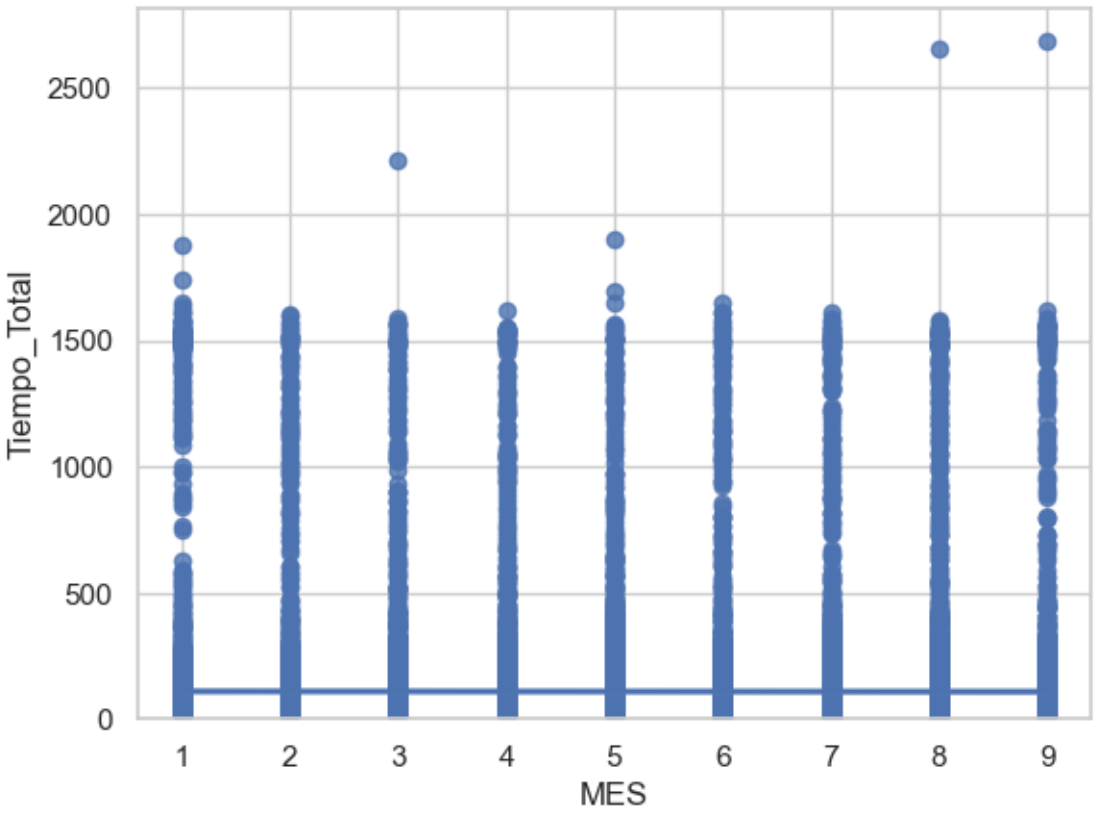

[ ]:
```
# Primero, asegúrate de que tus variables categóricas estén ordenadas
df['Turnos'] = df['Turnos'].astype('category')
df['Turnos'] = df['Turnos'].cat.as_ordered()

# Convierte la columna categórica en una variable numérica
df['Turnos'] = df['Turnos'].cat.codes

# Luego, crea el gráfico de regresión
sns.set(style="whitegrid")
sns.regplot(x="Turnos", y="Tiempo_Total", data=df)
plt.ylim(0,)
plt.show()
```

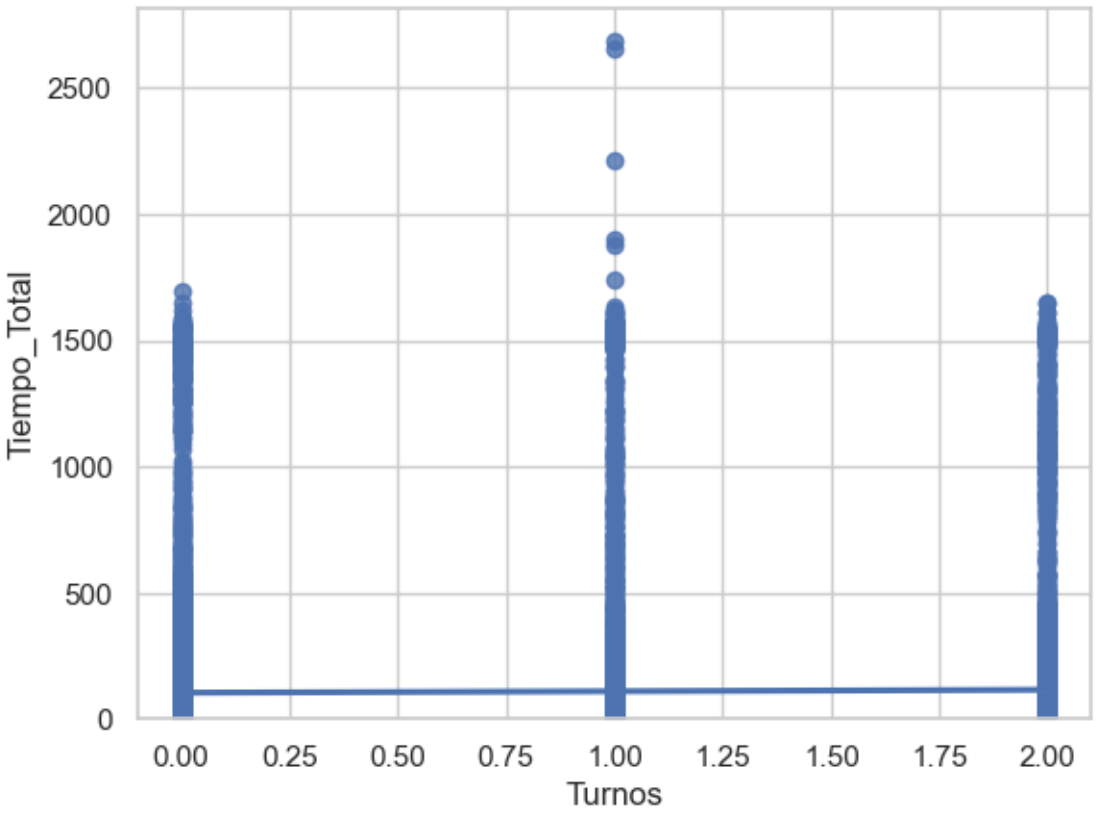

A medida que aumenta el tamaño del motor, aumenta el precio: esto indica una correlación directa positiva entre estas dos variables. El tamaño del motor parece ser un buen predictor de precio ya que la línea de regresión es casi una línea diagonal perfecta.

Visualicemos ahora highway-mpg y price. A medida que aumenta highway-mpg, el precio baja: esto indica un relación inversa/negativa entre estas dos variables. highway-mpg podría predecir el precio.

El gráfico de histograma también permite realizar un análisis sobre la variable numérica. Se utiliza el tipo de gráfico de Matplotlib hist sobre la variable age.

[ ]:
```
df['Tiempo_Total'].hist(figsize = (5,5))
plt.show
```

[ ]:
```
<function matplotlib.pyplot.show(close=None, block=None)>
```

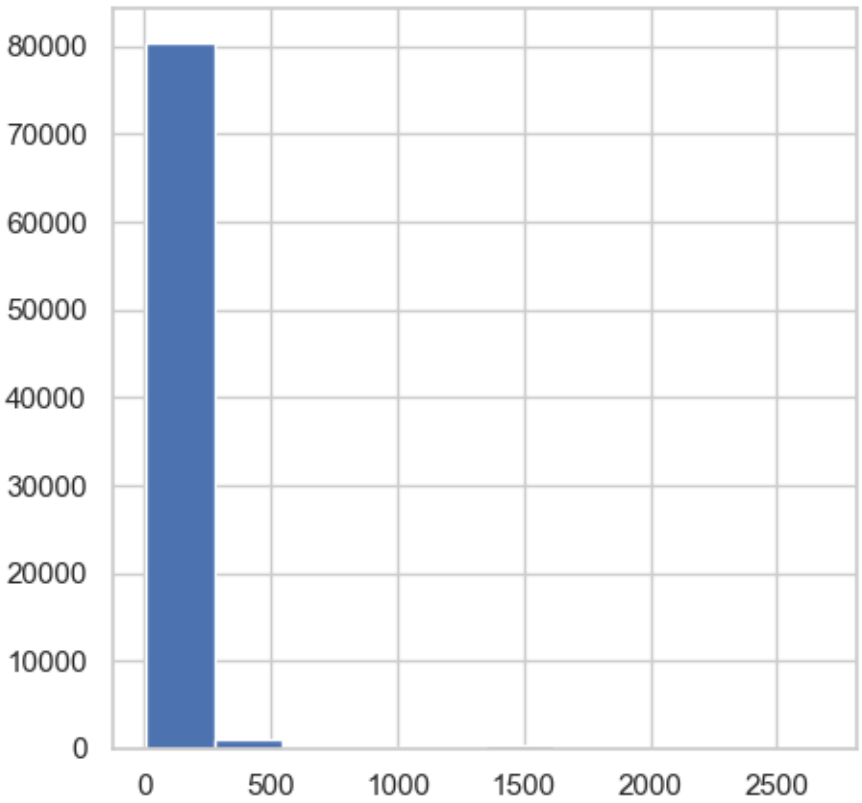

[ ]:
```
df['HOUR'].hist(figsize = (5,5))
plt.show
```

[ ]:
```
<function matplotlib.pyplot.show(close=None, block=None)>
```

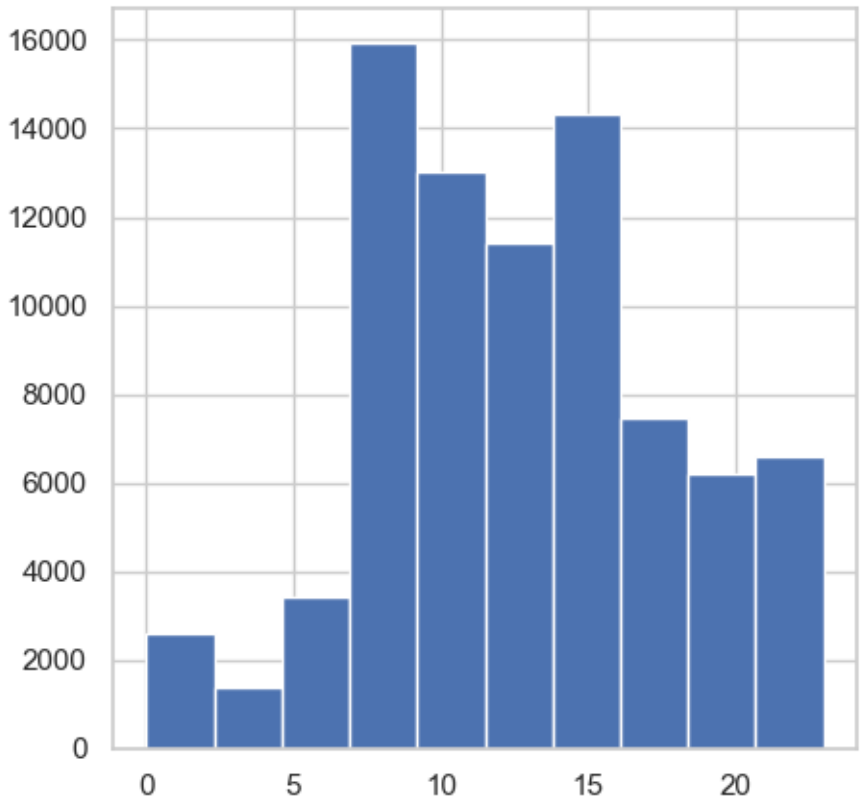

[ ]:
```
df['DIA'].hist(figsize = (5,5))
plt.show
```

[ ]:
```
<function matplotlib.pyplot.show(close=None, block=None)>
```

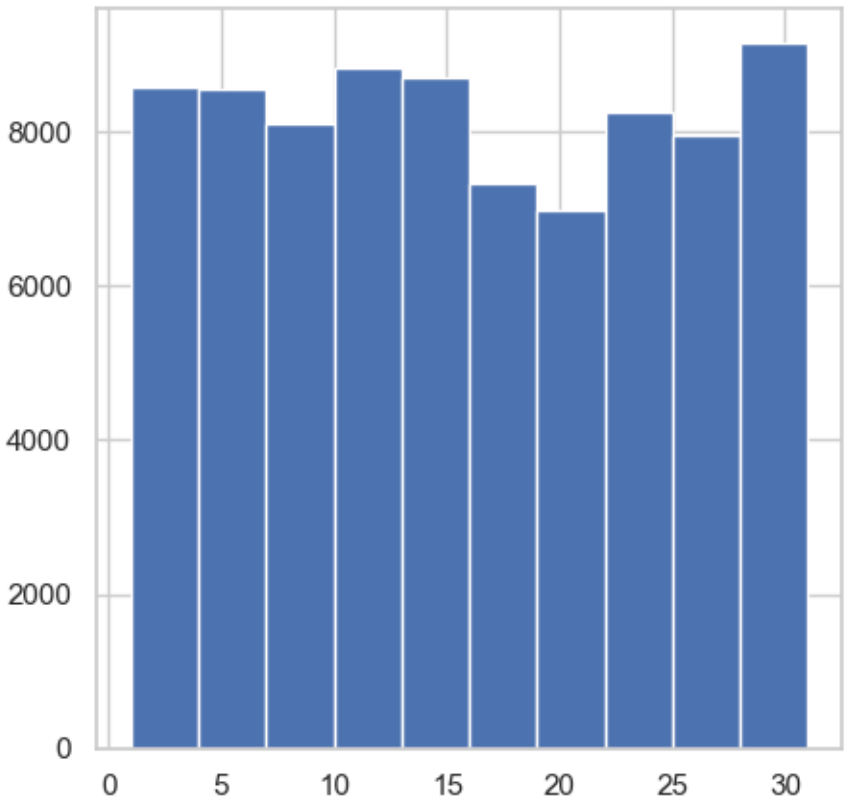

Variables categóricas

Estas son variables que describen una 'característica' de una unidad de datos y se seleccionan de un pequeño grupo de categorías. Las variables categóricas pueden tener el tipo objeto o int64. Una buena forma de visualizar variables categóricas es mediante el uso de diagramas de caja.

Mostremos un solo atributo, y contemos cuantos ejemplos hay de cada categoría. En este caso el atributo make que es la marca del carro:

[ ]:
```
sns.set(style="whitegrid")
sns.catplot(x="Turnos", kind="count", palette="ch:.25", data=df, height = 8,␣
 ↪aspect = 3)
```

```
c:\Users\Victor.Gomez\AppData\Local\Programs\Python\Python311\Lib\site-
packages\seaborn\axisgrid.py:118: UserWarning: The figure layout has changed to
tight
  self._figure.tight_layout(*args, **kwargs)
```

[ ]:
```
<seaborn.axisgrid.FacetGrid at 0x1b6b9ffa810>
```

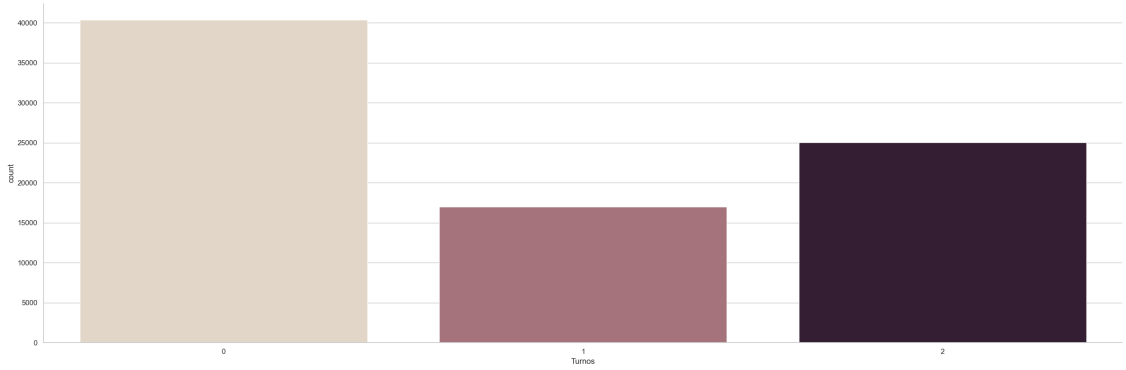

[ ]:
```
sns.set(style="whitegrid")
sns.catplot(x="HOUR", y="Tiempo_Total", hue_order="class", kind="bar", data=df,␣
 ↪height = 8, aspect = 3)
```

```
c:\Users\Victor.Gomez\AppData\Local\Programs\Python\Python311\Lib\site-
packages\seaborn\axisgrid.py:118: UserWarning: The figure layout has changed to
tight
  self._figure.tight_layout(*args, **kwargs)
```

[ ]:
```
<seaborn.axisgrid.FacetGrid at 0x1b6ba008e50>
```

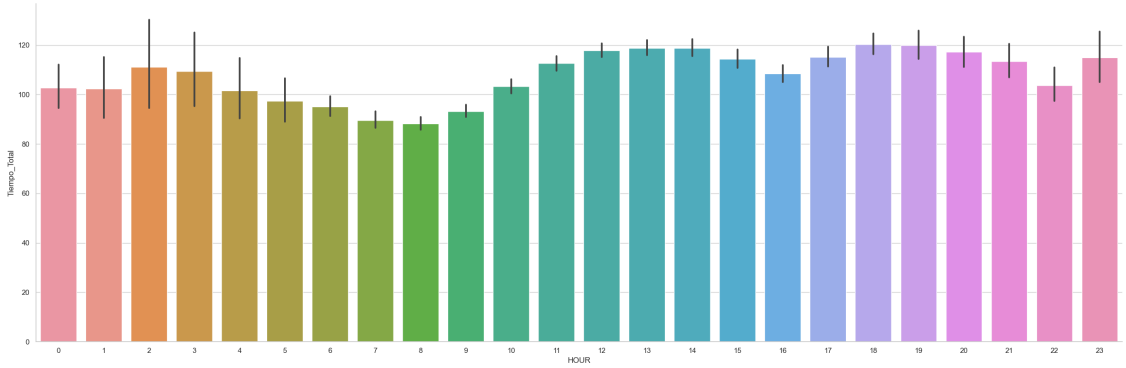

AHORA TÚ:

Visualice las variables stroke y price utilizando regplot. ¿Qué tipo de relación hay entre las variables?

[ ]:
```
# Escribe tu código aquí y presiona Shift+Enter para ejecutar

sns.set(style="whitegrid")
sns.regplot(x="DIA", y="Tiempo_Total", data=df)
```

[ ]: <Axes: xlabel='DIA', ylabel='Tiempo_Total'>

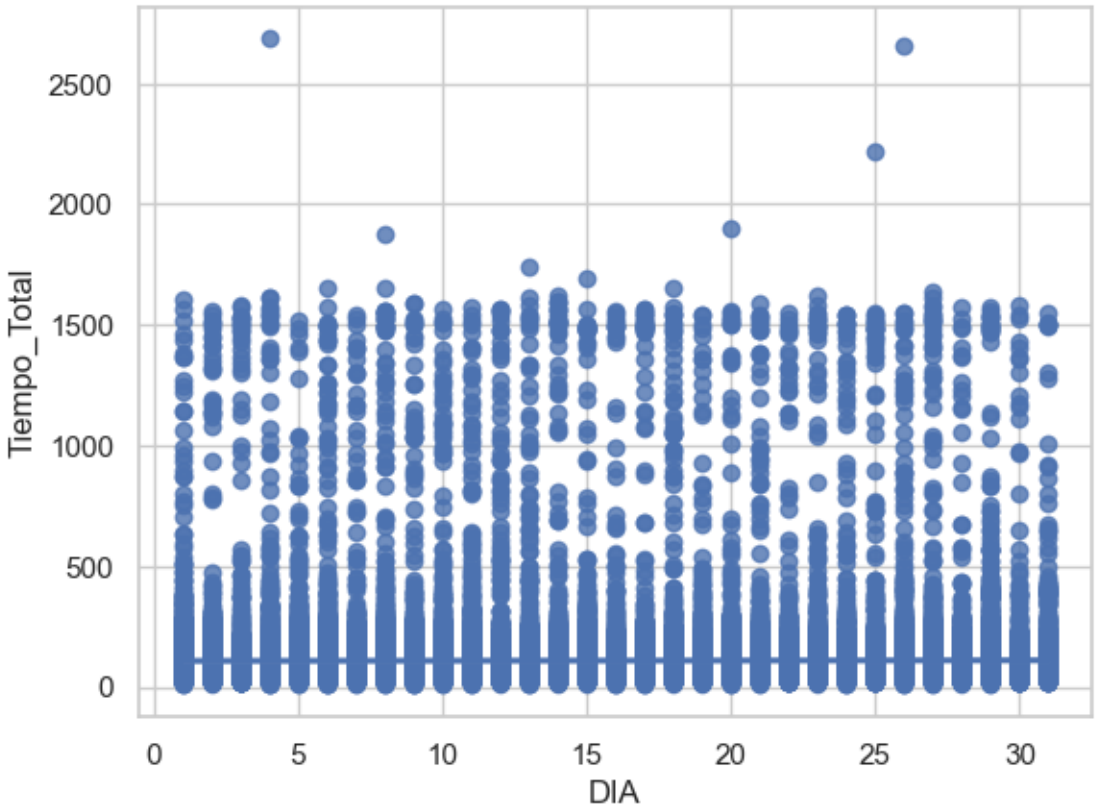

##Graficar las estadísticas

Podemos identificar la simentría de los datos utilizando gráficos de histograma:

[ ]:
```
#Histograma del atributo "length"
sns.distplot(df.Turnos)
```

```
C:\Users\Victor.Gomez\AppData\Local\Temp\ipykernel_14576\1764428100.py:2:
UserWarning:

`distplot` is a deprecated function and will be removed in seaborn v0.14.0.

Please adapt your code to use either `displot` (a figure-level function with
similar flexibility) or `histplot` (an axes-level function for histograms).

For a guide to updating your code to use the new functions, please see
https://gist.github.com/mwaskom/de44147ed2974457ad6372750bbe5751

  sns.distplot(df.Turnos)
```

[ ]: <Axes: xlabel='Turnos', ylabel='Density'>

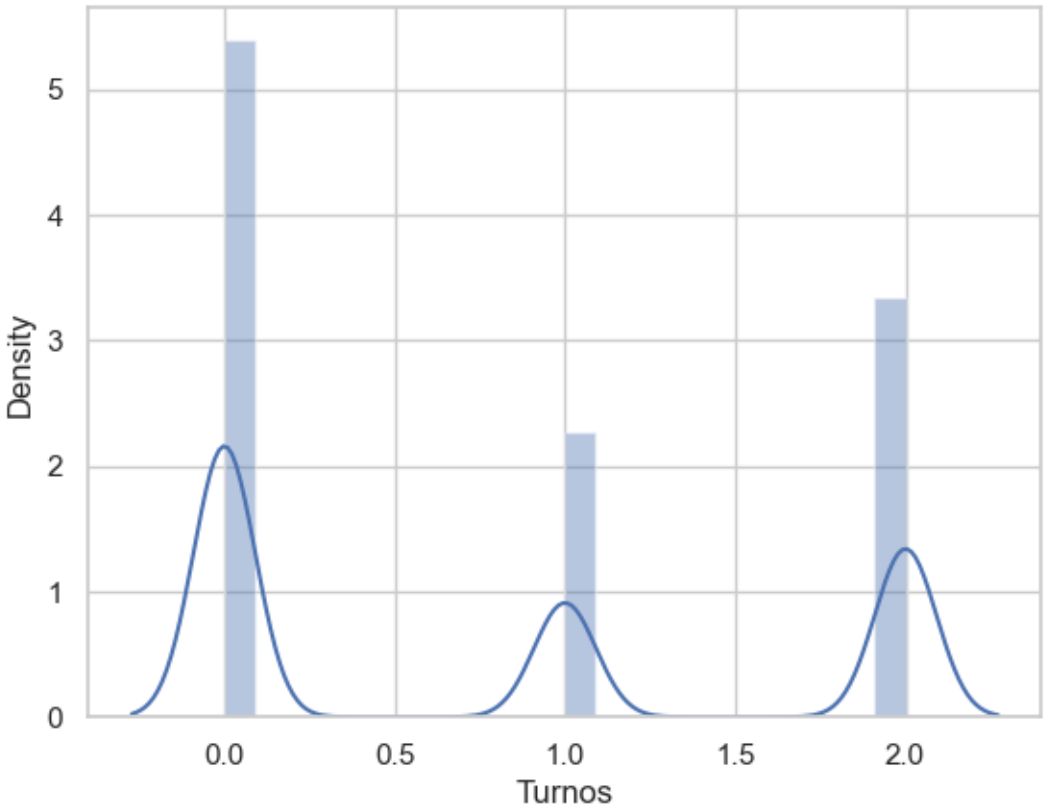

[ ]:
```
df['Turnos'].hist(figsize = (6,6))
plt.show
```

[ ]: <function matplotlib.pyplot.show(close=None, block=None)>

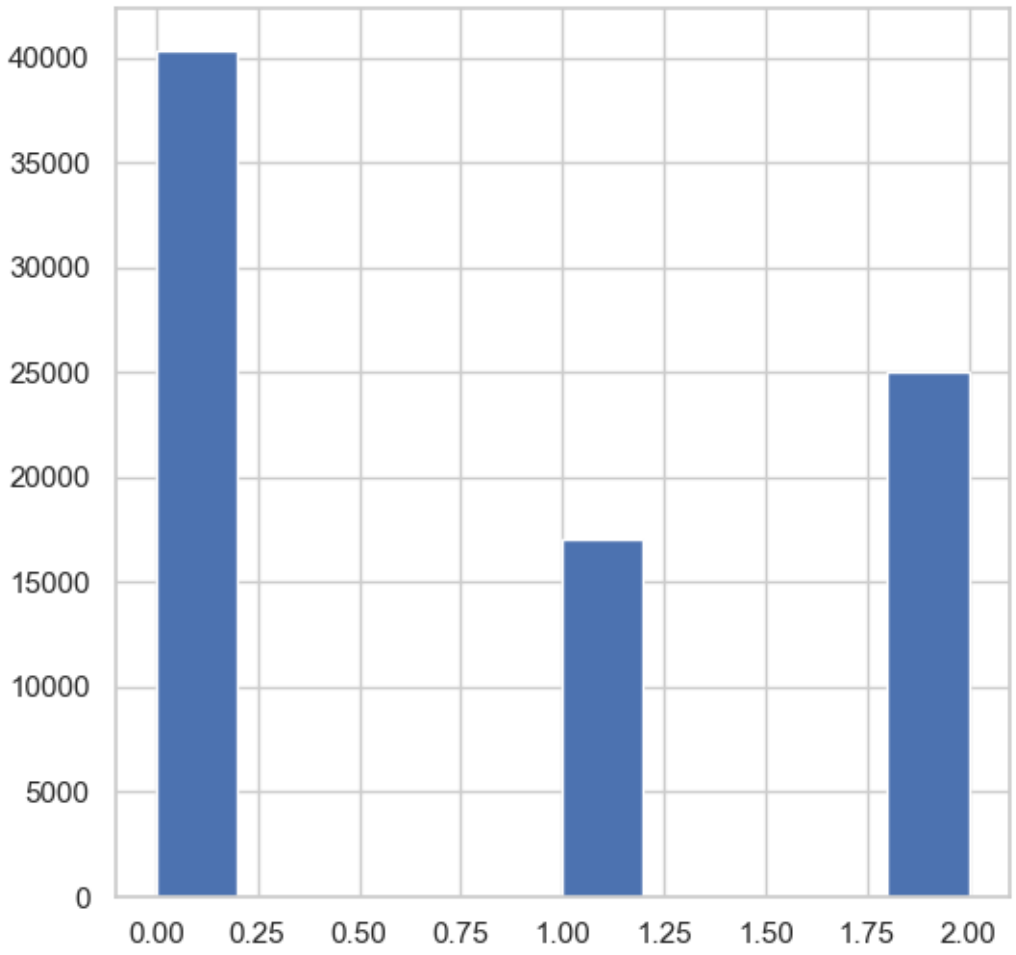

[ ]:
```
sns.displot(df['Turnos'])
```

```
c:\Users\Victor.Gomez\AppData\Local\Programs\Python\Python311\Lib\site-
packages\seaborn\axisgrid.py:118: UserWarning: The figure layout has changed to
tight
  self._figure.tight_layout(*args, **kwargs)
```

[ ]:
```
<seaborn.axisgrid.FacetGrid at 0x1b6ba034850>
```

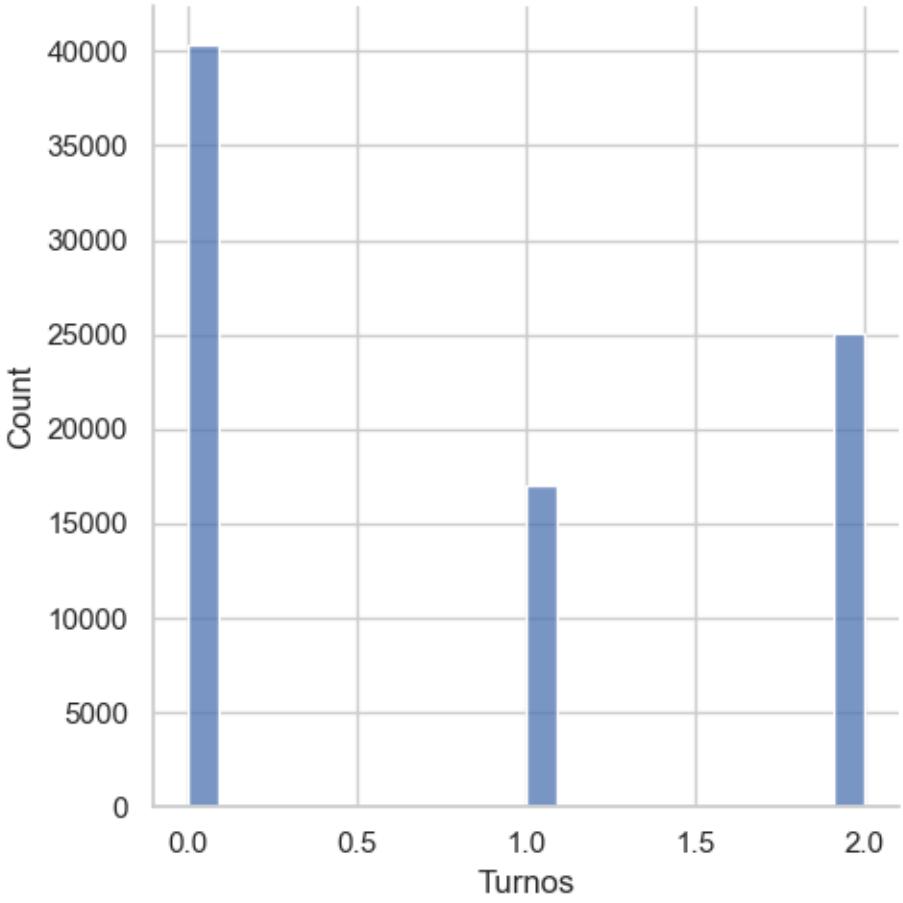

[ ]:
```
mean = df['Turnos'].mean()
median = df['Turnos'].median()
mode = df['Turnos'].mode()
skew = df['Turnos'].skew()
kurt = df['Turnos'].kurt()
print("La media es:", mean)
print("La mediana es:", median)
print("La moda es:", mode)
print("El sesgo es:", skew)
print("La kurtosis es:", kurt)
```

```
La media es: 0.8142229664142885
La mediana es: 1.0
La moda es: 0    0
Name: Turnos, dtype: int8
El sesgo es: 0.3684999729645169
La kurtosis es: -1.5835310691072397
```

AHORA TÚ:

Seleccione una variable y visualice su histograma. ¿Qué tipo de simentría tiene?

[ ]:
```
# Escribe tu código aquí y presiona Shift+Enter para ejecutar
sns.distplot(df.HOUR)
```

```
C:\Users\Victor.Gomez\AppData\Local\Temp\ipykernel_14576\8436205.py:2:
UserWarning:

`distplot` is a deprecated function and will be removed in seaborn v0.14.0.

Please adapt your code to use either `displot` (a figure-level function with
similar flexibility) or `histplot` (an axes-level function for histograms).

For a guide to updating your code to use the new functions, please see
https://gist.github.com/mwaskom/de44147ed2974457ad6372750bbe5751

  sns.distplot(df.HOUR)
```

[ ]: `<Axes: xlabel='HOUR', ylabel='Density'>`

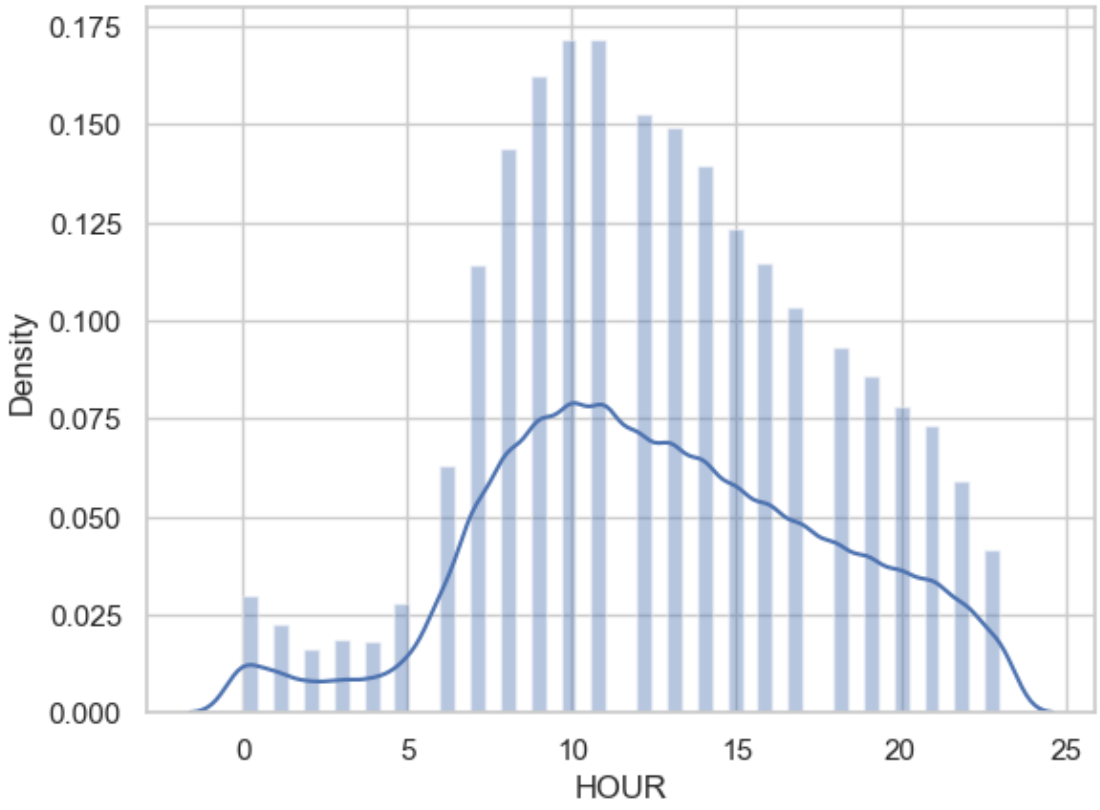

La dispersión de datos se puede comprobar también mediante los gráficos de tipo boxplot:

[ ]:
```
sns.boxplot(x=df.Tiempo_Total)
```

[ ]:
```
<Axes: xlabel='Tiempo_Total'>
```

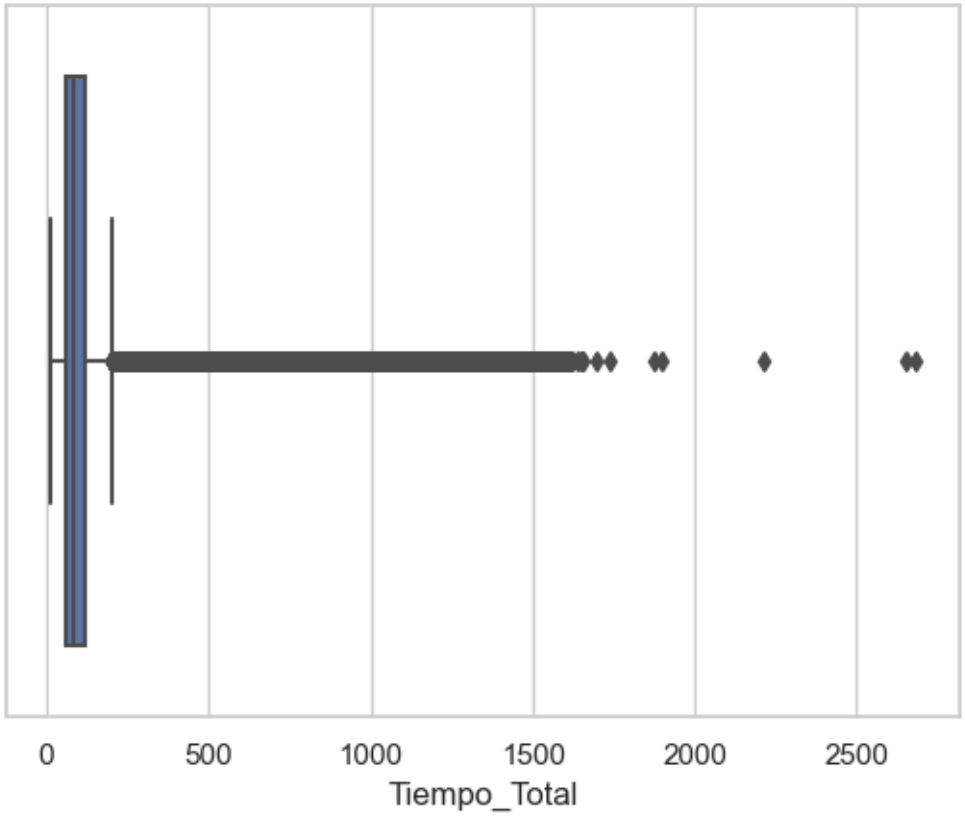

Representar más de una gráfico tipo boxplot permite comparar la dispersión de los datos al poder ver los resultados de forma conjunta. Veamos la relación entre body-style y price.

[ ]:
```
sns.boxplot(x="HOUR", y="Tiempo_Total", data=df)
```

[ ]:
```
<Axes: xlabel='HOUR', ylabel='Tiempo_Total'>
```

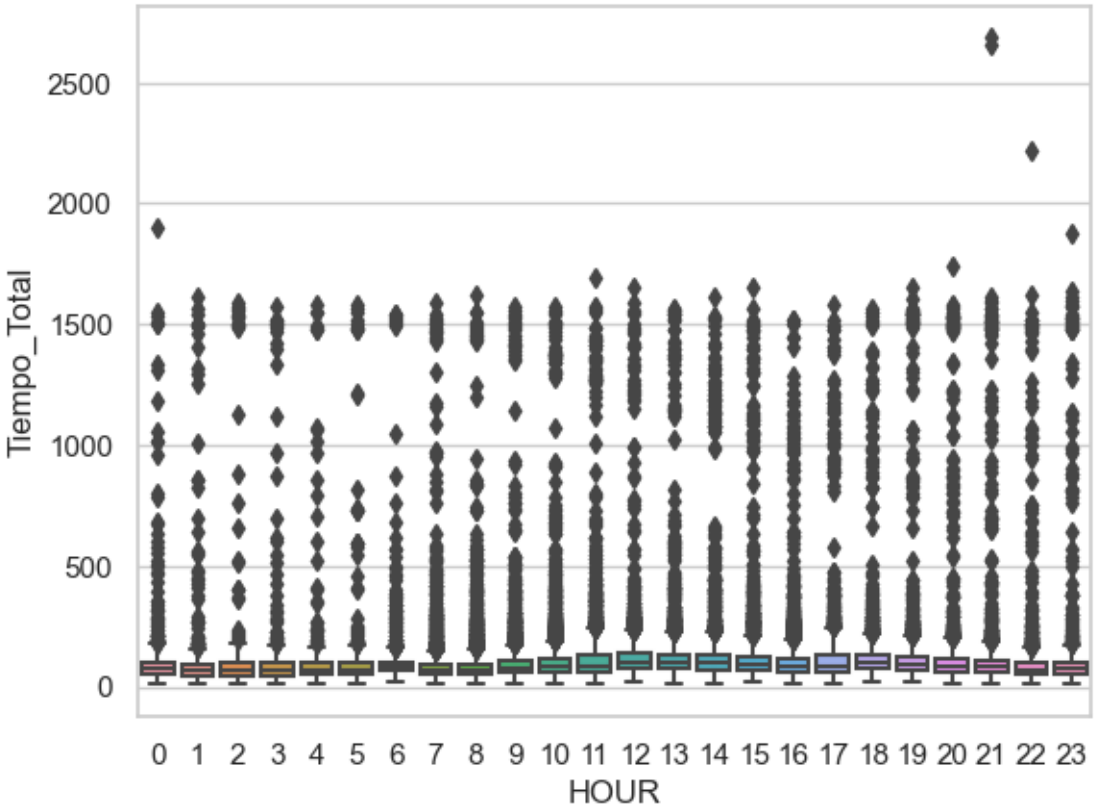

Vemos que las distribuciones de precios entre las diferentes categorías de estilo de cuerpo tienen una superposición significativa, por lo que el estilo de cuerpo no sería un buen predictor del precio.

AHORA TÚ:

Visualice las variables engine-location y price utilizando un gráfico de BoxPlot

[ ]:
```
# Escribe tu código aquí y presiona Shift+Enter para ejecutar
sns.boxplot(x="DIA", y="Tiempo_Total", data=df)
```

[ ]:
```
<Axes: xlabel='DIA', ylabel='Tiempo_Total'>
```

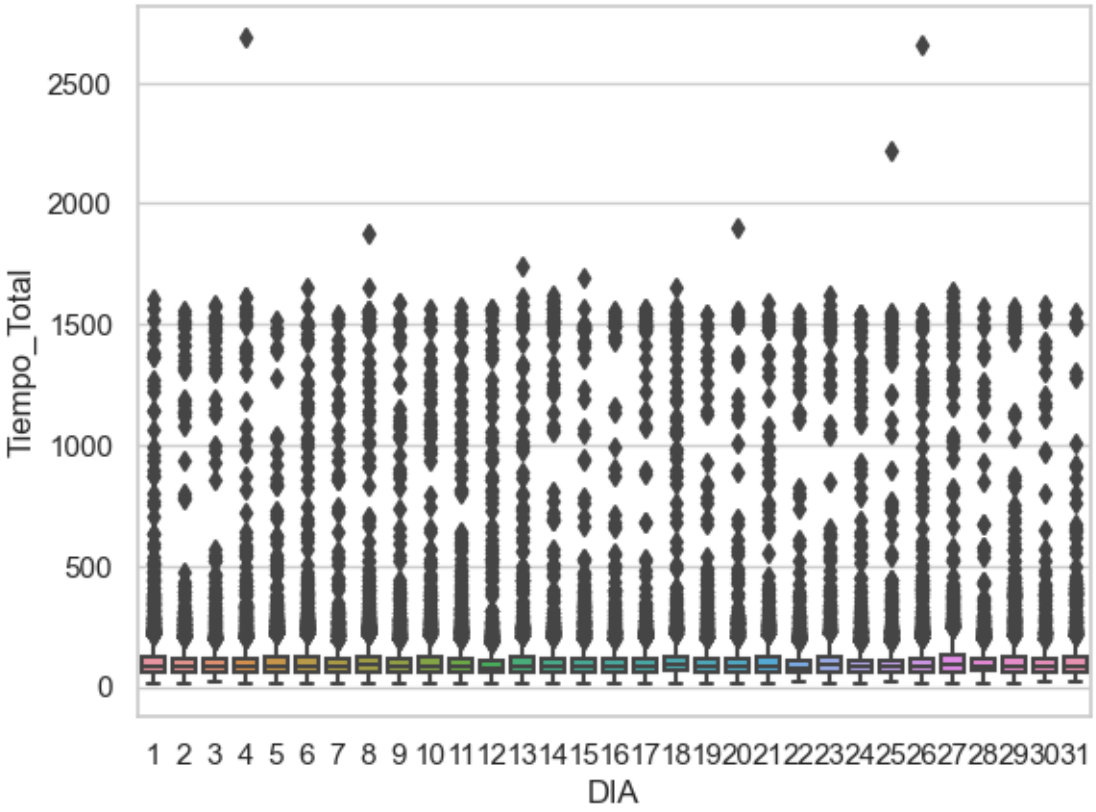

##Exportar los datos

De la misma forma, Pandas nos permite guardar el conjunto en formato CSV con el método dataframe.to_csv(), puede añadir la ruta al archivo y el nombre con comillas dentro de los corchetes.

Por ejemplo, si guarda el dataframe df como automobile.csv en su equipo local o en este caso dentro de Google Colab, podría usar la sintaxis siguiente:

[ ]:
```
path="URGENCIAS.csv"
df.to_csv(path)
```

Podemos leer y guardar con otros formatos y usar funciones similares a pd.read_csv() y df.to_csv() para otros formatos de datos, las funciones se muestran en la siguiente tabla:

Data Formate	Read	Save
csv	`pd.read_csv()`	`df.to_csv()`
json	`pd.read_json()`	`df.to_json()`
excel	`pd.read_excel()`	`df.to_excel()`
hdf	`pd.read_hdf()`	`df.to_hdf()`
sql	`pd.read_sql()`	`df.to_sql()`
...	...	...

##Links de ayuda interesantes:

Graficos Seaborn: https://seaborn.pydata.org/examples/index.html

Plotting with categorical data: https://seaborn.pydata.org/tutorial/categorical.html

Visualizing statistical relationships: https://seaborn.pydata.org/tutorial/relational.html

Funciones Generales y Ayuda Pandas: https://pandas.pydata.org/pandas-docs/stable/reference/general_functions.html

Ayuda de Pandas para función read_csv: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.read_csv.html?highlight=pandas%20read_csv#pandas.read_csv

How to Perform Exploratory Data Analysis with Seaborn: https://towardsdatascience.com/how-to-perform-exploratory-data-analysis-with-seaborn-97e3413e841d